

ЛЕКЦИЯ 13

ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ. ПОСТАНОВКА ЗАДАЧИ

В отличие от линейной регрессии, где зависимая переменная Y непрерывна, во многих практических задачах нас интересует *бинарный исход*: $Y \in \{0, 1\}$

Пример

Риелтор хочет предсказать, будет ли квартира продана в течение 30 дней после выставления на рынок

$Y_i = 1$ – продана

$Y_i = 0$ – не продана

X_i – размер скидки от начальной цены продавца (в %)

Почему линейная регрессия не подходит?

Если применить модель $Y_i = \theta_0 + \theta_1 X_i + \varepsilon_i$ возникают три проблемы:

1. $Y = \theta_0 + \theta_1 X$ это прямая заданная на всей числовой оси и значения функции будут выходить за пределы отрезка $[0; 1]$
2. Для простой линейной регрессии мы полагали постоянную дисперсию ошибок, а в случае бинарной переменной с вероятностью успеха $p(X)$, дисперсия зависит от X_i
3. Для простой линейной регрессии мы полагали нормальность ошибок, а здесь ошибки, как и сама функция принимают только 2 значения и имеют дискретное распределение Бернулли

Вывод: нужна модель, которая:

- Ограничивает прогнозы интервалом $(0; 1)$
- Интерпретируется как вероятность $P(Y = 1 | X)$
- Сохраняет линейную структуру для удобства оценки

МОДЕЛЬ ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

Определение. Пусть $p(X) = P(Y = 1 | X)$ условная вероятность успеха.

Моделью логистической регрессии будем называть

$$p(X) = \frac{1}{1 + e^{-(\theta_0 + \theta_1 X)}}, \text{ где}$$

θ_0, θ_1 – параметры модели

2

$\theta_0 + \theta_1 X$ – линейный фактор

Замечание. Функцию $\sigma(z) = \frac{1}{1 + e^{-z}}$ принято называть логистической

функцией (сигмоидой)

Не сложно установить ее свойства:

1. $\sigma(z) \in (0; 1), \forall z \in \mathbb{R}$
2. $\sigma(0) = 0.5$
3. $\lim_{z \rightarrow -\infty} \sigma(z) = 0, \lim_{z \rightarrow \infty} \sigma(z) = 1$
4. Монотонно возрастает

Определение. Функцию $\text{Odds}(X) = \frac{p(X)}{1 - p(X)}$ называют *шансом* события

$P(Y = 1 | X)$

Теорема. Логарифм шанса линейно зависит от X , причем

$$\ln \left(\frac{p(X)}{1 - p(X)} \right) = \theta_0 + \theta_1 X$$

Доказательство:

$$p(X) = \frac{1}{1 + e^{-(\theta_0 + \theta_1 X)}} \Rightarrow 1 - p(X) = 1 - \frac{1}{1 + e^{-(\theta_0 + \theta_1 X)}} = \frac{e^{-(\theta_0 + \theta_1 X)}}{1 + e^{-(\theta_0 + \theta_1 X)}}$$


$$\text{Тогда } \frac{p(X)}{1 - p(X)} = \frac{1}{e^{-(\theta_0 + \theta_1 X)}} = e^{(\theta_0 + \theta_1 X)}$$

$$\text{И } \ln \left(\frac{p(X)}{1 - p(X)} \right) = \theta_0 + \theta_1 X$$

Замечание. Параметр θ_1 показывает, на сколько изменяется логарифм шансов наступления события $Y = 1$ при увеличении X фактора на одну единицу

Иллюстрация 1

Эти рисунки демонстрирует два взаимно обратных преобразования, которые являются фундаментом логистической регрессии. Он показывает, как мы переходим от линейных значений к вероятностям и обратно



Свойства:

1. Логистическая функция сжимает R в $(0, 1)$
2. Логарифм шанса растягивает $(0, 1)$ в R , восстанавливая линейность

ОЦЕНКА ПАРАМЕТРОВ: МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

В отличие от МНК, в логистической регрессии параметры находятся через метод максимального правдоподобия

Будем исходить из того, что для одного наблюдения выполняется следующее $Y_i \sim B_{p_i}$ бинарная переменная имеет распределение Бернулли с вероятностью успеха для каждого наблюдения $p_i = P(Y_i = 1 | X_i)$. При

этом считаем, что $p_i = \sigma(\theta_0 + \theta_1 X_i)$

Вероятность конкретного исхода Y_i имеет вид

$$P(Y = Y_i | X_i, \theta) = p_i^{Y_i} (1 - p_i)^{1 - Y_i}$$

При $Y_i = 1$ получим $P(Y = 1 | X_i, \theta) = p_i^1 (1 - p_i)^0$

При $Y_i = 0$ получим $P(Y = 0 | X_i, \theta) = p_i^0 (1 - p_i)^1$

Теорема. Функция правдоподобия для выборки из n независимых наблюдений имеет вид $L(\theta_0, \theta_1) = \prod_{i=1}^n p_i^{Y_i} (1 - p_i)^{1 - Y_i}$, а логарифмическая

функция правдоподобия $l(\theta_0, \theta_1) = \sum_{i=1}^n (Y_i \ln p_i + (1 - Y_i) \ln (1 - p_i))$

Доказательство:

Из независимости наблюдений получаем произведение вероятностей отдельных исходов. Используя свойства логарифма – вторую формулу

ЧИСЛЕННАЯ ОПТИМИЗАЦИЯ: КАК НАЙТИ ОЦЕНКИ?

В линейной регрессии МНК давал нам формулы для оценок. В логистической регрессии нет таких формул, поскольку уравнения

$$\left\{ \frac{\partial l(\theta_0, \theta_1)}{\partial \theta_0} = 0, \frac{\partial l(\theta_0, \theta_1)}{\partial \theta_1} = 0 \right\}$$

слишком сложные – их нельзя разрешить относительно θ_0, θ_1

В этом случае можно воспользоваться численной оптимизацией, например алгоритм Ньютона-Рафсон

Шаг 0: начинаем с произвольных значений, например $\theta_0^{(0)} = 0, \theta_1^{(0)} = 0$

Шаг 1: вычисляем градиент (направление наискорейшего роста)

$$\left(\frac{\partial l}{\partial \theta_0}(\theta_0^{(0)}, \theta_1^{(0)}), \frac{\partial l}{\partial \theta_1}(\theta_0^{(0)}, \theta_1^{(0)}) \right)$$


Шаг 2: делаем шаг в направлении градиента

$$\theta_j^{new} = \theta_j^{old} + \alpha \frac{\partial l}{\partial \theta_j}(\theta_0^{(0)}, \theta_1^{(0)}), \text{ где } \alpha \text{ размер шага}$$

Шаг 3: проверяем изменилось ли правдоподобие значительно?

- Да $\rightarrow$ повторяем с Шага 1
- Нет $\rightarrow$ остановка, мы нашли максимум

Иллюстрация 2



- (1) Как меняются значения θ_0, θ_1 от итерации к итерации. Видно, что постепенно параметры перестают меняться – достигнута сходимость
- (2) Как убывает отрицательный логарифм правдоподобия (функция потерь). Алгоритм минимизирует эту функцию
- (3) Траектория движения в пространстве параметров (θ_0, θ_1) . Старт из точки $(0,0)$, движение к оптимуму.
- (4) Итоговая логистическая кривая, построенная по найденным параметрам. Она наилучшим образом (в смысле максимального правдоподобия) разделяет проданные и непроданные квартиры.

СВОЙСТВА ОЦЕНОК ММП

Несмотря на численный характер оценок, они обладают теми же важными свойствами, что и в линейной регрессии

1. Состоятельность: при $n \rightarrow \infty$ оценки сходятся к истинным значениям

2. Асимптотическая нормальность: при больших n распределение оценок близко к нормальному
3. Асимптотическая эффективность: среди всех состоятельных оценок имеют наименьшую дисперсию (при больших n)

Все эти свойства гарантируются асимптотически. При малых $n < 50$ оценки могут быть смещёнными

ИНТЕРПРЕТАЦИЯ КОЭФФИЦИЕНТОВ

Из $\ln \left(\frac{p(X)}{1-p(X)} \right) = \theta_0 + \theta_1 X$ найдем изменение логарифма шанса при

изменении наблюдаемого фактора на 1

$$\ln(\text{Odds}(X+1)) - \ln(\text{Odds}(X)) = \theta_0 + \theta_1(X+1) - \theta_0 - \theta_1 X = \theta_1$$

Т. о. параметр θ_1 показывает на сколько изменится логарифм шанса при изменении наблюдаемого фактора на 1

Рассмотрим отношение шансов

Теорема. При увеличении фактора X на 1, шансы успеха умножаются на e^{θ_1}

Доказательство:


Из предыдущих выкладок имеем

$$\ln(\text{Odds}(X+1)) - \ln(\text{Odds}(X)) = \theta_0 + \theta_1(X+1) - \theta_0 - \theta_1 X = \theta_1$$

По свойству логарифма

$$\ln \left(\frac{\text{Odds}(X+1)}{\text{Odds}(X)} \right) = \theta_1 \text{ или } \frac{\text{Odds}(X+1)}{\text{Odds}(X)} = e^{\theta_1}$$

Иллюстрация 3



Оценки: $\theta_0 = -1.341, \theta_1 = 0.099$

Odds Ratio = 1.104 (рост шансов на 1% скидки)

Каждая точка — это квартира, расположена только на двух уровнях (продана, не продана)

Красная линия — это оцененная вероятность. Показывает, как вероятность продажи растёт с увеличением скидки. Для любой скидки кривая показывает долю квартир, которые продаются за 30 дней

Синяя линия — это граница принятия решения по вероятности. Если выше, предсказываем — продана, ниже — не продана

Зеленая линия показывает критическую скидку (граница принятия решений), при которой вероятность равна 0,5. Если вы хотите продать квартиру за 30 дней с вероятностью более 50%, давайте скидку не менее 12.5%

ГРАНИЦА ПРИНЯТИЯ РЕШЕНИЯ

Определение. Порогом принятия бинарного решения называют величину τ , для которого $\hat{Y} = \begin{cases} 1, & \text{если } p(X) \geq \tau \\ 0, & \text{если } p(X) < \tau \end{cases}$

Замечание. Обычно выбирают $\tau = 0.5$

Теорема. При пороге $\tau = 0.5$ граница между классами определяется уравнением $\theta_0 + \theta_1 X = 0$

Доказательство:

$$p(X) \geq 0.5 \Rightarrow \sigma(\theta_0 + \theta_1 X) \geq 0.5$$

Поскольку $\sigma(\theta_0 + \theta_1 X)$ монотонна и $\sigma(0) = 0.5$, то $\theta_0 + \theta_1 X = 0$

Посмотрим, как сдвиг порога влияет на границы принятия решений

$$p(X) = \tau \Rightarrow \theta_0 + \theta_1 X = \ln \frac{\tau}{1-\tau} \Rightarrow X_\tau = \frac{\ln \frac{\tau}{1-\tau} - \theta_0}{\theta_1}$$

Поясним на примере

Будем понимать под чувствительностью долю реально проданных квартир, которые модель правильно предсказала как проданные, а под специфичностью долю реально непроданных квартир, которые модель правильно предсказала как непроданные


- $\tau < 0.5$ больше объектов классифицируются как 1. Выше чувствительность (почти все реально проданные квартиры будут предсказаны верно), ниже специфичность (много непроданных квартир ошибочно предсказаны как проданные)
- $\tau > 0.5$ строже отбор. Выше специфичность (если модель говорит «не продается» — почти наверняка так и будет), ниже чувствительность (много реально проданных квартир модель пропустила, предсказав как «непродаваемые»)

Выбор порога — это компромисс:

- Хотите найти больше положительных случаев? Снизьте порог (но будет больше ложных срабатываний)
- Хотите меньше ошибок? Повысьте порог (но пропустите много реальных случаев)

Выбор зависит от того, что дороже стоит — пропустить продажу или пообещать и не продать

Иллюстрация 4



- (1) Визуализация показывает: как одна и та же модель (одна кривая вероятности) может давать совершенно разные решения в зависимости от выбранного порога классификации. Сдвиг порога = сдвиг границы: Изменяя τ , мы двигаем вертикальную линию классификации
- (2) Справа много фиолетовых точек (правильно предсказанные продажи)
- Слева много оранжевых точек (правильно предсказанные непроджи)

ОЦЕНКА КАЧЕСТВА КЛАССИФИКАЦИИ

После построения модели мы получим прогнозы для каждого конкретного значения фактора (для каждой конкретной квартиры). Но как понять, насколько хороша наша модель?

Простой подход посчитать долю верных ответов недостаточен, потому что не различает типы ошибок

Поэтому в рассмотрение вводится матрица ошибок

Идея состоит в том, чтобы разделить все прогнозы на 4 категории в зависимости от того, что было на самом деле и что предсказала модель

Введем обозначения

Обозначение	Расшифровка	Смысл
TN	Истинно отрицательный	Правильно предсказали отрицательный класс
TP	Истинно положительный	Правильно предсказали положительный класс

FP	Ложно отрицательный	Ошиблись в предсказании положительного класса
FN	Ложно положительный	Ошиблись в предсказании отрицательного класса

Пример

TN – Квартира не продана, и мы правильно предсказали

TP – Квартира продана, и мы правильно предсказали

FP – Квартира не продана, но мы сказали «продается»

FN – Квартира продана, но мы сказали «не продается»

Теперь, когда у нас есть матрица ошибок, мы можем посчитать разные метрики, каждая из которых отвечает на свой вопрос

- Доля правильных прогнозов. Как часто модель вообще не ошибается?

$$\text{Accuracy} = \frac{\text{Правильные прогнозы}}{\text{Все прогнозы}} = \frac{TP + TN}{N}$$

Полезна, когда классы сбалансированы и когда все ошибки одинаково важны. Обманчива при несбалансированных классах

- Точность положительных прогнозов. Какую долю составляют правильные положительные прогнозы среди всех предсказанных положительных?

$$\text{Precision} = \frac{\text{Правильные положительные}}{\text{Все предсказанные положительные}} = \frac{TP}{TP + FP}$$

Полезна, когда «дорого стоит ложная тревога»

- Полнота. Какую долю объектов положительного класса модель правильно определила?

$$\text{Recall} = \frac{\text{Найденные положительные}}{\text{Все реально положительные}} = \frac{TP}{TP + FN}$$

Полезна, когда дорого стоит пропуск цели. Обманчива при несбалансированных классах

Замечание. Нельзя одновременно максимизировать Precision и Recall

Пример

Осторожный риелтор (не хочет рисковать репутацией)

Precision высокий (почти все обещания сбываются)

Recall низкий (много потенциальных продаж упущено)

Агрессивный риелтор (не хочет увеличить продажи, даже ценой потери репутации)

Precision низкий (много ложных обещаний)

Recall высокий (ловим почти все продажи)

Зададимся еще одним вопросом: можно ли оценить качество модели независимо от выбора порога?

На этот вопрос отвечает ROC-кривая

Идея состоит в том, что, перебирая все пороги от 0 до 1 мы считаем

$Recall = TPR = \frac{TP}{TP + FN}$ и отношение $FPR = \frac{FP}{TN + FP}$. Тогда отклады-

вая по оси Ox FPR , а по оси Oy TPR , получаем кривую, каждая точка которой один порог τ

Как же интерпретируют ROC-кривую?

Идеальная модель:

- $TPR = 1$ (нашли все продажи)
- $FPR = 0$ (ни одну непроданную не назвали продаваемой)
- Точка (0, 1) — верхний левый угол

Случайное угадывание:

- $TPR = FPR$ (сколько нашли, столько и ошиблись)
- Диагональная линия от (0,0) до (1,1)

Хорошая модель:

- Кривая выгибается вверх-влево
- Чем ближе к верхнему левому углу, тем лучше

Определение. AUC – это числовая характеристика качества бинарной классификации, равная площади фигуры, ограниченной ROC-кривой и осями координат

Замечание. AUC показывает способность модели ранжировать объекты – присваивать объектам положительного класса более высокие вероятности, чем объектам отрицательного класса

Площадь под кривой:

- Идеальная модель: кривая проходит через (0,1). $AUC = 1.0$
- Случайная модель: диагональная линия. $AUC = 0.5$
- Хорошая модель: кривая выгибается влево-вверх. $AUC > 0.7$

Почему AUC полезна?


Преимущества:

1. Не зависит от порога классификации
 - Accuracy, Precision, Recall зависят от выбора τ
 - AUC оценивает модель в целом, независимо от порога
2. Работает при несбалансированных классах
 - Если 95% объектов – класс 0, Accuracy будет высоким даже для плохой модели
 - AUC корректно учитывает оба класса
3. Инвариантна к масштабу вероятностей
 - Важна только относительная упорядоченность объектов
 - Неважно, выдаёт модель 0.9 или 0.7 – важно, что для класса 1 вероятность выше
4. Единая числовая метрика
 - Удобно сравнивать разные модели
 - Чем выше AUC, тем лучше модель ранжирует

Недостатки (ограничения):

1. Не показывает калибровку вероятностей
 - Модель может иметь $AUC=0.9$, но предсказывать вероятности 0.99 для всех объектов класса 1
 - AUC измеряет ранжирование, а не точность вероятностей
2. Не учитывает бизнес-стоимость ошибок
 - FP и FN могут иметь разную цену
 - AUC усредняет по всем порогам, а не только по оптимальному для задачи
3. Может быть оптимистичной при сильном дисбалансе
 - Если класс 1 составляет 1% данных, даже AUC может быть завышена

Иллюстрация 5



Accuracy: 0.64

AUC: 0.696

Цветовая матрица 2×2 показывает распределение прогнозов по четырём категориям. Тёмные ячейки – правильные прогнозы, светлые ячейки – ошибки модели

Оранжевая кривая – ROC-кривая (зависимость TPR от FPR при разных порогах)

Синяя пунктирная линия – диагональ случайного угадывания (AUC = 0.5)

Каждая точка на кривой = один порог классификации τ