

1. Исследование гипотез по выборке data_rgr_2.csv

Вариант: А-1

Группа: А

Единицы измерения: мс

Объём выборки: $n = 108$

Уровень значимости: $\alpha = 0.05$

В работе рассматриваются три проверки статистических гипотез по столбцам X1–X4 из файла data_rgr_2.csv. Во всех пунктах используется уровень значимости $\alpha = 0.05$. Если в условии явно не указано иное, альтернативная гипотеза считается двусторонней.

1.1. Исходные данные

Для каждой переменной вычислены основные выборочные характеристики.

Показатель	X1	X2	X3	X4
Объём выборки n	108	108	108	108
Выборочное среднее $\bar{x}$	81.8216	85.8578	61.3049	11.2469
Выборочная дисперсия s^2	94.7577	81.6582	65.9490	121.4921
Выборочное std. отклонение s	9.7344	9.0365	8.1209	11.0223
Минимум	60.37	67.61	36.51	0.01
Максимум	100.30	115.84	86.58	72.17

Перед проверкой гипотез построены диагностические графики.

Диагностика нормальности для X1 и X2




Рис. 1. Диагностика нормальности для X1 и X2




Рис. 2. Сравнение распределений X1 и X2 по boxplot

1.2. 1. Проверка равенства математических ожиданий X1 и X2

Проверяем гипотезу

$$H_0 : \mu_1 = \mu_2, H_1 : \mu_1 \neq \mu_2.$$

По выборочным характеристикам:

$$|(x)_1 = 81.8216, |(x)_2 = 85.8578,$$

$$s_1^2 = 94.7577, s_2^2 = 81.6582.$$

Дисперсии близки, поэтому используем двухвыборочный критерий Стьюдента с объединённой дисперсией:

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2},$$

$$t = \frac{|(x)_1 - |(x)_2}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}.$$

После подстановки получаем

$$t_{\text{набл}} = -3.1580, df = 214.$$

Критическое значение для двусторонней проверки при $\alpha = 0.05$:

$$t_{\text{кр}} \approx 1.97.$$

Так как $|t_{\text{набл}}| > t_{\text{кр}}$, гипотеза H_0 отвергается.

Следовательно, на уровне значимости 0.05 имеются статистически значимые основания считать, что математические ожидания двух совокупностей различаются.

1.3. 4.4. Непараметрический критерий для двух выборок

Для тех же выборок X1 и X2 применим непараметрический критерий Манна—Уитни. Этот критерий подходит для сравнения двух независимых выборок и не требует предположения о нормальности распределений.

Проверяем гипотезы:

$$H_0 : F_1(x) = F_2(x), q \quad H_1 : F_1(x) \neq F_2(x).$$

Для выборок объема $n_1 = n_2 = 108$ получаем статистику Манна–Уитни

$$U = 4633,$$

а при нормальной аппроксимации

$$z \approx -2.61,$$

что соответствует

$$p \approx 0.0091 < 0.05.$$

Следовательно, гипотеза H_0 отвергается. Итак, распределения X_1 и X_2 статистически значимо различаются и по непараметрическому критерию.

Сравнение с п. 4.2 показывает, что выводы совпадают: и параметрический t-критерий, и критерий Манна–Уитни указывают на различие между X_1 и X_2 . Это могло произойти потому, что различие между выборками выражено достаточно сильно и сохраняется даже без предположения о нормальности.




Рис. 3. Гистограмма X_3 и гипотезное значение математического ожидания

1.4. 2. Проверка гипотезы $H_0: \mu = 62.55$ по столбцу X_3

Проверяем гипотезу

$$H_0: \mu = 62.55, H_1: \mu \neq 62.55.$$

Используем одновыборочный t-критерий:

$$t = \frac{|(x) - \mu_0|}{\frac{s}{\sqrt{n}}}.$$

По данным выборки:

$$|(x) = 61.3049, s = 8.1209.$$

Тогда

$$t_{\text{набл}} = -1.5933, df = 107.$$

Критическое значение для двусторонней проверки при $\alpha = 0.05$:

$$t_{\text{кр}} \approx 1.98.$$

Так как $|t_{\text{набл}}| < t_{\text{кр}}$, гипотеза H_0 не отвергается.

Иными словами, данные X3 не противоречат предположению о среднем значении 62.55 мс.

1.5. 3. Проверка гипотезы о показательном распределении X4

Проверяем гипотезу H_0 : X4 имеет показательное распределение с параметром $\lambda = 0.085$.

где плотность имеет вид

$$f(x) = \lambda e^{-\lambda x}, x \geq 0.$$

Для критерия согласия Пирсона используем 8 интервалов одинаковой теоретической вероятности. Границы интервалов выбраны по квантилям экспоненциального распределения:

$$b_i = -\frac{\ln(1 - \frac{i}{8})}{\lambda}, i = 1, 2, \dots, 7.$$

При этом ожидаемая частота в каждом интервале равна

$$E_i = \frac{n}{8} = 13.5,$$

что удовлетворяет условию применимости критерия χ^2 .

Интервал, мс	Набл. частота O_i	Ожид. частота E_i	$\left(\frac{(O_i - E_i)^2}{E_i}\right)$
[0; 1.571)	18	13.5	1.500
[1.571; 3.385)	14	13.5	0.019
[3.385; 5.530)	10	13.5	0.907
[5.530; 8.155)	11	13.5	0.463
[8.155; 11.539)	12	13.5	0.019
[11.539; 16.309)	13	13.5	0.019
[16.309; 24.464)	20	13.5	3.130
[24.464; $+\infty$)	10	13.5	0.907
Итого	108	108.0	7.111

Статистика критерия Пирсона:

$$\chi_{\text{набл}}^2 = 7.1111.$$

Число степеней свободы:

$$df = 8 - 1 = 7.$$

Критическое значение при $\alpha = 0.05$:

$$\chi_{\text{кр}}^2 \approx 14.067.$$

Так как $\chi_{\text{набл}}^2 < \chi_{\text{кр}}^2$, гипотеза H_0 не отвергается.

Таким образом, выборка X4 согласуется с показательным распределением с параметром $\lambda = 0.085$.




Рис. 4. Наблюдаемые и ожидаемые частоты для X4

1.6. Итоговый вывод

- Гипотеза о равенстве математических ожиданий для X1 и X2 **отвергается**.
- Гипотеза $H_0: \mu = 62.55$ по столбцу X3 **не отвергается**.
- Гипотеза о показательном распределении X4 с параметром $\lambda = 0.085$ **не отвергается**.

Итого, по данным выборки выявлено различие между X1 и X2, тогда как X3 и X4 не противоречат сформулированным в задании гипотезам.