

Лабораторная работа: Построение простой линейной регрессии

Вариант 1

4 мая 2026 г.

Цель работы

Построить простую линейную регрессию для заданной выборки, оценить коэффициенты регрессии, построить доверительные интервалы и сделать статистические выводы.

1 Данные

Файл с данными: `variant_1_data.csv`. Ниже приведена таблица исходных наблюдений (i , x , y).

	<u>i</u>	<u>x</u>	<u>y</u>
1	0.7775		0.7706
2	1.3653		2.0631
3	2.0717		4.5496
4	2.3275		3.4272
5	2.3641		2.9128
6	2.9501		4.7224
7	3.2074		4.2667
8	3.5111		5.5796
9	4.0744		4.6881
10	4.2488		5.1874
11	4.7173		3.0364
12	4.8468		4.5618
13	5.4100		6.0698
14	5.5097		5.3279
15	6.3898		6.8934
16	6.8485		6.5860
17	7.0493		6.5276
18	7.5180		7.0654
19	7.7663		7.8603
20	8.0611		7.2422
21	8.1863		7.2499
22	9.0410		7.5808

	i	x	y
23		9.4203	8.0560
24		9.4376	8.2323
25		10.1248	7.6338
26		10.4685	8.4081
27		10.9821	8.5309
28		11.3358	8.6068
29		11.5871	8.6055
30		12.2170	10.3130

2 Расчёты характеристик

2.1 Средние и суммы квадратов отклонений

Сначала вычислим средние значения по формулам:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{30} \sum_{i=1}^{30} x_i = 6.460507$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{1}{30} \sum_{i=1}^{30} y_i = 6.085180$$

Далее рассчитаем суммы квадратов отклонений:

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = 327.493632$$

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = 206.729514$$

2.2 Оценки коэффициентов регрессии

По методу наименьших квадратов:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{206.729514}{327.493632} = 0.631247$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 6.085180 - 0.631247 \times 6.460507 = 2.007002$$

Уравнение регрессии: $\hat{y} = 2.0070 + 0.6312x$

Интерпретация: при увеличении x на 1 единицу значение y в среднем увеличивается на 0.6312 единиц.

2.3 Остатки и остаточная сумма квадратов

Остатки (residuals) рассчитываются как отклонения фактических значений от прогнозируемых:

$$e_i = y_i - \hat{y}_i$$

Таблица прогнозных значений и остатков:

	i	x_i	y_i	$\hat{y}_i$	e_i
	e_i^2				
1	0.7775	0.7706	2.4978	-1.7272	
2.9831					
2	1.3653	2.0631	2.8688	-0.8057	
0.6492					
3	2.0717	4.5496	3.3148	1.2348	
1.5248					
4	2.3275	3.4272	3.4762	-0.0490	
0.0024					
5	2.3641	2.9128	3.4993	-0.5865	
0.3440					
6	2.9501	4.7224	3.8692	0.8532	
0.7279					
7	3.2074	4.2667	4.0317	0.2350	
0.0552					
8	3.5111	5.5796	4.2234	1.3562	
1.8393					
9	4.0744	4.6881	4.5790	0.1091	
0.0119					
10	4.2488	5.1874	4.6890	0.4984	
0.2484					
11	4.7173	3.0364	4.9848	-1.9484	
3.7962					
12	4.8468	4.5618	5.0665	-0.5047	
0.2548					
13	5.4100	6.0698	5.4221	0.6477	
0.4196					
14	5.5097	5.3279	5.4850	-0.1571	
0.0247					
15	6.3898	6.8934	6.0405	0.8529	
0.7274					
16	6.8485	6.5860	6.3301	0.2559	
0.0655					
17	7.0493	6.5276	6.4569	0.0707	
0.0050					
18	7.5180	7.0654	6.7527	0.3127	
0.0978					
19	7.7663	7.8603	6.9095	0.9508	
0.9041					
20	8.0611	7.2422	7.0956	0.1466	
0.0215					
21	8.1863	7.2499	7.1746	0.0753	
0.0057					
22	9.0410	7.5808	7.7141	-0.1333	
0.0178					

	i	x_i	y_i	$\hat{y}_i$	e_i
	e_i^2				
23	9.4203		8.0560	7.9535	0.1025
0.0105					
24	9.4376		8.2323	7.9645	0.2678
0.0717					
25	10.1248		7.6338	8.3983	-0.7645
0.5844					
26	10.4685		8.4081	8.6152	-0.2071
0.0429					
27	10.9821		8.5309	8.9394	-0.4085
0.1669					
28	11.3358		8.6068	9.1627	-0.5559
0.3090					
29	11.5871		8.6055	9.3213	-0.7158
0.5124					
30	12.2170		10.3130	9.7190	0.5940
0.3529					

Остаточная сумма квадратов (RSS):

$$\text{RSS} = \sum_{i=1}^n e_i^2 = 16.777049$$

2.4 Оценка дисперсии ошибок и стандартные ошибки

Оценка дисперсии ошибок:

$$s^2 = \frac{\text{RSS}}{n-2} = \frac{16.777049}{30-2} = \frac{16.777049}{28} = 0.599180$$

Остаточное стандартное отклонение:

$$s = \sqrt{s^2} = \sqrt{0.599180} = 0.774067$$

Стандартная ошибка для $\hat{\beta}_1$:

$$\text{SE}(\hat{\beta}_1) = \frac{s}{\sqrt{S_{xx}}} = \frac{0.774067}{\sqrt{327.493632}} = \frac{0.774067}{18.0971} = 0.042774$$

Стандартная ошибка для $\hat{\beta}_0$:

$$\text{SE}(\hat{\beta}_0) = s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} = 0.774067 \sqrt{\frac{1}{30} + \frac{(6.460507)^2}{327.493632}} = 0.310381$$

2.5 Доверительные интервалы для коэффициентов

На уровне значимости $\alpha = 0.05$ критическое значение распределения Стьюдента с числом степеней свободы $df = n - 2 = 28$:

$$t_{1-\alpha/2, df=28} = t_{0.975, 28} = 2.0484$$

95% доверительный интервал для β_0 :

$$\hat{\beta}_0 \pm t \cdot \text{SE}(\hat{\beta}_0) = 2.007002 \pm 2.0484 \times 0.310381 = [1.3712, 2.6428]$$

95% доверительный интервал для β_1 :

$$\hat{\beta}_1 \pm t \cdot \text{SE}(\hat{\beta}_1) = 0.631247 \pm 2.0484 \times 0.042774 = [0.5436, 0.7189]$$

Вывод о значимости: Ноль не попадает в доверительный интервал для β_1 , следовательно, коэффициент наклона β_1 статистически значимо отличается от нуля при уровне значимости $\alpha = 0.05$. Это подтверждает значимость линейной зависимости.

2.6 Коэффициент детерминации

Общая сумма квадратов:

$$\text{TSS} = \sum_{i=1}^n (y_i - \bar{y})^2 = 147.274524$$

Коэффициент детерминации:

$$R^2 = 1 - \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{16.777049}{147.274524} = 0.8861 \quad (88.61\%)$$

Интерпретация: модель объясняет 88.61% вариации зависимой переменной y . Это указывает на хорошее качество модели.

3 Построение графиков

Ниже представлены графики: диаграмма рассеяния и оценённая прямая с 95% доверительным интервалом.




Рис. 1: Диаграмма рассеяния (Вариант 1)




Рис. 2: Простая линейная регрессия с 95% доверительным интервалом

3.1 Анализ диаграммы рассеяния

Диаграмма рассеяния (рис. 1) показывает, что между переменными x и y наблюдается явная положительная линейная зависимость. Точки в целом следуют линейному тренду: с увеличением x значения y тенденциально возрастают. Это визуально подтверждает целесообразность применения простой линейной регрессии.

3.2 Анализ графика регрессии и доверительного интервала

На графике регрессии с 95% доверительным интервалом (рис. 2) видны следующие особенности:

1. **Узкий интервал вблизи среднего значения.** Доверительный интервал имеет минимальную ширину (наиболее узкий) в той области графика, где x близок к среднему значению $\bar{x} = 6.4605$. Это объясняется формулой стандартной ошибки:

$$SE(\hat{y}(x_0)) = s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

При $x_0 = \bar{x}$ второе слагаемое под корнем обнуляется, стандартная ошибка минимальна.

2. **Расширение интервала при удалении от центра.** По мере удаления x_0 от $\bar{x}$ (как влево, так и вправо) терм $(x_0 - \bar{x})^2$ возрастает, и доверительный интервал расширяется. Это создаёт характерную форму, напоминающую «песочные часы» или расширяющуюся воронку.
3. **Уверенность в прогнозе в центре диапазона.** Прогноз является наиболее точным при значениях x , близких к $\bar{x}$, где накоплено больше информации (в смысле дисперсии).
4. **Неуверенность при экстраполяции.** На концах диапазона (особенно за пределами наблюдаемых значений) интервал существенно расширяется, что предостерегает от экстраполяции.

3.3 Характеристика качества модели по графику

1. **Наблюдаемые точки и линия регрессии:** На графике видно, что точки данных достаточно тесно группируются вокруг оценённой линии регрессии. Большинство точек находятся вблизи прямой, что говорит о хорошей аппроксимации моделью.
2. **Остатки и случайность:** Визуальный осмотр показывает, что остатки (вертикальные отклонения точек от линии) распределяются относительно случайно, без видимого систематического тренда. Это подтверждает предположение о независимости и одинаковости распределения ошибок (гомоскедастичность).
3. **Коэффициент детерминации:** $R^2 = 0.8861 = 88.61\%$ означает, что модель объясняет почти 89% доли дисперсии отклика. По шкале:
 - $R^2 < 0.5$ — низкое качество;
 - $0.5 \leq R^2 < 0.7$ — среднее качество;
 - $0.7 \leq R^2 < 0.9$ — хорошее качество;
 - $R^2 \geq 0.9$ — отличное качество.

В нашем случае $R^2 = 0.8861$ соответствует диапазону хорошего качества.

4. **Диапазон прогнозируемых значений:** Оценённая регрессионная прямая охватывает диапазон от ≈ 2.5 (при $x \approx 0.8$) до ≈ 9.7 (при $x \approx 12.2$), что разумно соответствует наблюдаемому диапазону $y \in [0.77, 10.31]$.
5. **Вывод:** Построенная линейная модель адекватна для данной выборки и может использоваться для прогнозирования значений y при заданных x в диапазоне наблюдаемых данных.

4 Итоговая сводка результатов

5 Статистические выводы

1. Коэффициент наклона $\hat{\beta}_1 = 0.6312 > 0$, следовательно зависимость между x и y положительная.
2. Ноль не попадает в 95% доверительный интервал для β_1 , поэтому линейная зависимость статистически значима на уровне $\alpha = 0.05$.
3. Модель объясняет примерно 88.6% изменчивости зависимой переменной y — качество модели можно считать хорошим.

Заключение

Построена простая линейная модель, проведены необходимые оценки и сделаны статистически обоснованные выводы. Графическое представление подтверждает адекватность выбранной модели для текущей выборки.

Показатель	Значение
Объём выборки n	30
Среднее x	6.460507
Среднее y	6.085180
S_{xx}	327.493632
S_{xy}	206.729514
$\hat{\beta}_0$	2.007002
$\hat{\beta}_1$	0.631247
RSS	16.777049
TSS	147.274524
s^2	0.599180
s	0.774067
$SE(\hat{\beta}_0)$	0.310381
$SE(\hat{\beta}_1)$	0.042774
$t_{0.975,28}$	2.0484
95% ДИ для β_0	[1.3712, 2.6428]
95% ДИ для β_1	[0.5436, 0.7189]
R^2	0.8861 (88.61%)

Таблица 3: Сводка основных результатов анализа

Приложения: исходный код `main (2).py`, файл с данными `variant1data.csv`,