ИТМО

Факультет Программной Инженерии и Компьютерной техники

ЛАБОРАТОРНАЯ РАБОТА 3. ЛИНЕЙНАЯ РЕГРЕССИЯ НА ДАННЫХ О ЖИЛЬЕ КАЛИФОРНИИ

Аннотация – В работе выполнен анализ датасета о жилье в Калифорнии (17 000 записей, 9 признаков). Получена описательная статистика, проведена предобработка данных, реализована линейная регрессия методом наименьших квадратов собственным кодом на языке Python с использованием NumPy. Построены и сравнены три модели с разными наборами признаков по коэффициенту детерминации R^2, введен синтетический признак. Результаты оформлены в виде отчёта с графиками и таблицами.

Ключевые слова: линейная регрессия, метод наименьших квадратов, коэффициент детерминации, данные о жилье, Python, NumPy

Выполнили

Ануфриев А.С. 465029

Проверил

Болдырева Е. А.

07.11.2026

1 Цели и задачи

Цель работы — построение и сравнение моделей линейной регрессии для прогнозирования стоимости жилья в Калифорнии методом наименьших квадратов без применения готовых библиотек регрессии. Основные задачи:

1. получить и визуализировать описательную статистику по датасету (количество, среднее, стандартное отклонение, минимум, максимум, квантили);
2. выполнить предобработку данных: обработку отсутствующих значений, кодирование категориальных признаков, нормировку;
3. разделить данные на обучающую и тестовую выборки;
4. реализовать линейную регрессию методом наименьших квадратов собственным кодом (минимизация суммы квадратов разностей фактических и предсказанных значений), используя только NumPy и Pandas;
5. построить три модели с разными наборами признаков;
6. оценить каждую модель коэффициентом детерминации R^2 и сравнить результаты;
7. в качестве бонуса ввести синтетический признак.

2 Теоретические сведения

Линейная мультимножественная регрессия описывает зависимость результативного признака y от нескольких факторов $x_1, \ldots, x_p$:

$$\hat{y} = a + b_1 x_1 + \ldots + b_p x_p. \tag{1}$$

Метод наименьших квадратов определяет оценки параметров вектором $B = (a, b_1, \ldots, b_p)^\top$ как

$$B = (X^\top X)^{-1} X^\top Y, \tag{2}$$

где X — матрица признаков с первым столбцом единиц (свободный член), Y — вектор наблюдений целевой переменной. Качество модели оценивается коэффициентом детерминации

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}. \tag{3}$$

3 Исходные данные

Исходный датасет содержит 17 000 записей о жилых районах Калифорнии. Все 9 признаков числовые, пропущенных значений и категориальных признаков в исходных данных отсутствуют. Целевая переменная — *median_house_value* (медианная стоимость дома, тыс. долл.). Ограничение исходных данных: значения стоимости ограничены сверху отметкой 500 000 (цензурное отсечение); записей на этой границе всего 22 (0,13

4 Ход работы

4.1 Загрузка данных и описательная статистика

Данные загружены из CSV-файла. Вычислены размер выборки, среднее значение, стандартное отклонение, минимум, максимум и квантили 25%, 50%, 75% для всех признаков (таблица 1).

Таблица 1: Описательная статистика по датасету.

Признак	count	mean	std	min	25%	50%	75%	max
longitude	17000	-119.56	2.01	-124.35	-121.79	-118.49	-118.00	-114.31
latitude	17000	35.63	2.14	32.54	33.93	34.25	37.72	41.95
housing_median_age	17000	28.59	12.59	1.0	18.0	29.0	37.0	52.0
total_rooms	17000	2643.66	2179.95	2.0	1462.0	2127.0	3151.25	37937.0
total_bedrooms	17000	539.41	421.50	1.0	297.0	434.0	648.25	6445.0
population	17000	1429.57	1147.85	3.0	790.0	1167.0	1721.0	35682.0
households	17000	501.22	384.52	1.0	282.0	409.0	605.25	6082.0
median_income	17000	3.88	1.91	0.50	2.57	3.54	4.77	15.00
median_house_value	17000	207300.91	115983.76	14999.0	119400.0	180400.0	265000.0	500001.0

Для целевой переменной построена гистограмма распределения (рисунок 1), для пары “доход населения — стоимость жилья” — диаграмма рассеяния (рисунок 2).

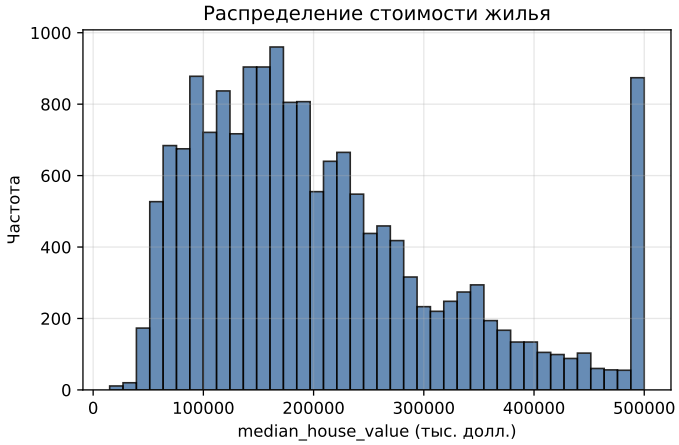


Рис. 1: Гистограмма распределения медианной стоимости жилья.

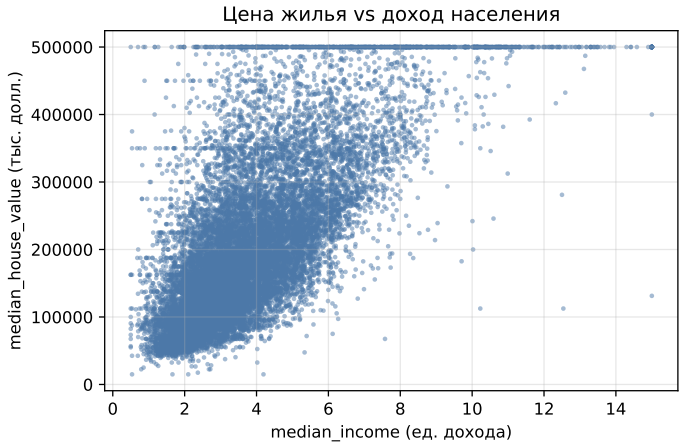


Рис. 2: Диаграмма рассеяния стоимости жилья от дохода населения.

4.2 Предобработка данных

Пропущенных значений в данных не обнаружено, категориальных признаков нет. Все числовые признаки нормированы стандартизацией (вычет среднего, деление на стандартное отклонение); целевая переменная не нормировалась.

4.3 Разделение на выборки

Данные перемешаны и разделены на обучающую (13 600 записей, 80%) и тестовую (3 400 записей, 20%) выборки.

4.4 Реализация линейной регрессии

Коэффициенты регрессии вычислены собственным кодом на языке Python с использованием NumPy по формуле $B = (X^\top X)^{-1} X^\top Y$, что эквивалентно минимизации суммы квадратов разностей фактических и предсказанных значений. Готовые средства регрессии не использовались.

4.5 Три модели и синтетический признак

Построены три модели с разными наборами признаков (таблица 2). В третью модель включён синтетический признак $rooms_per_household = total_rooms / households$ (бонусное задание).

Таблица 2: Сравнение трёх моделей линейной регрессии (признаки нормированы).

Модель	Признаки	R^2 на тестовой выборке
Модель 1	median_income	0.4978
Модель 2	median_income, housing_median_age	0.5376
Модель 3	median_income, total_rooms, households, rooms_per_household	0.5227

Оценочные коэффициенты моделей (включая свободный член, для нормированных признаков):

	Модель 1	Модель 2	Модель 3
Свободный член	207066.73	206962.89	207033.39
median_income	79512.76	81929.71	89613.01
housing_median_age	—	21519.53	—
total_rooms	—	—	-54374.09
households	—	—	56290.68
rooms_per_household	—	—	-6.13

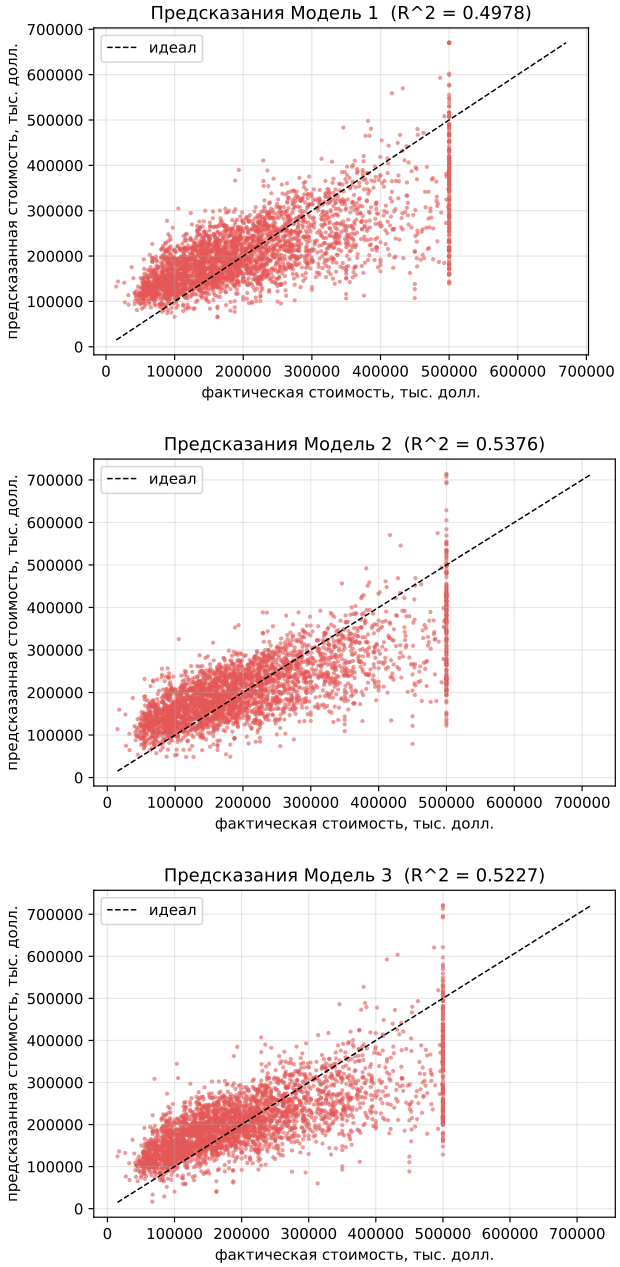


Рис. 3: Фактические против предсказанных значений на тестовой выборке для моделей 1, 2 и 3.

5 Выводы

Наилучшее качество среди трёх моделей показала Модель 2 (признаки: доход населения и возраст жилого дома), $R^2 \approx 0.54$ на тестовой выборке. Доход населения является

сильнейшим отдельным признаком ($R^2 \approx 0.50$ в одномерной модели). Добавление возраста дома повысило качество, а добавление в третью модель количества комнат, числа домохозяйств и синтетического признака не улучшило её ($R^2 \approx 0.52$), что связано с сильной линейной зависимостью (мультиколлинеарностью) между количеством комнат, числом домохозяйств и отношением комнат к домохозяйствам. Синтетический признак не дал преимущества при одновременном включении с его исходными компонентами.

6 Приложение

Минимальный фрагмент реализации метода наименьших квадратов (NumPy):

```
X_aug = np.column_stack([np.ones(len(X)), X])
B = np.linalg.inv(X_aug.T @ X_aug) @ X_aug.T @ y
y_pred = X_aug_test @ B
R2 = 1 - np.sum((y_true - y_pred)**2) / np.sum((y_true - y_true.mean())**2)
```

Полная реализация: скрипт расчётов, формирующий статистику, три модели, метрики R^2 и исходные данные для графиков.