Теория и вопросы защиты лабораторной работы 3: Линейная регрессия методами анализа данных

Ануфриев А.С. 465029

07.11.2026

1 Теоретические сведения

1.1 Множественная линейная регрессия

Зависимость результативного признака y от p факторов $x_1, \ldots, x_p$ описывается линейной моделью

$$y = a + b_1 x_1 + \ldots + b_p x_p + \varepsilon, \tag{1}$$

где a — свободный член, b_j — регрессионные коэффициенты, ε — случайная ошибка. Эмпирическая оценка:

$$\hat{y} = a + b_1 x_1 + \ldots + b_p x_p. \tag{2}$$

1.2 Метод наименьших квадратов

Оценки параметров получаются минимизацией суммы квадратов остатков $Q = \sum_i e_i^2 = (Y - XB)^\top (Y - XB)$. Дифференцирование по B даёт нормальное уравнение

$$B = (X^\top X)^{-1} X^\top Y, \tag{3}$$

где матрица X содержит первый столбец единиц (для свободного члена) и столбцы значений факторов, а Y — вектор наблюдений целевой переменной.

1.3 Предположения МНК (теорема Гаусса—Маркова)

1. модель специфицирована верно (линейная зависимость);
2. между факторами нет строгой линейной зависимости (отсутствие мультиколлинеарности);
3. ошибки случайны, математическое ожидание равно нулю, дисперсия постоянна (гомоскедастичн
4. ошибки не коррелированы между собой.

При выполнении этих условий оценки МНК являются наилучшими линейными несмещёнными оценками.

1.4 Коэффициент детерминации

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}, \tag{4}$$

показывает долю дисперсии целевой переменной, объясняемую моделью. Чем ближе R^2 к единице, тем лучше качество модели.

2 Вероятные вопросы защиты с ответами

1. **Что такое метод наименьших квадратов и в чём его суть?**
   МНК — способ оценки параметров регрессионной модели, минимизирующий сумму квадратов отклонений наблюдаемых значений зависимой переменной от значений, предсказанных моделью. Аналитически решение задаётся формулой $B = (X^\top X)^{-1} X^\top Y$.

2. **Зачем нужен первый столбец единиц в матрице X?**
   Столбец единиц соответствует свободному члену a модели — значению y, когда все факторы равны нулю. Он позволяет смещать регрессионную плоскость по оси y.

3. **Как вы проверяли отсутствие мультиколлинеарности?**
   В исходных данных категориальных признаков нет, все признаки числовые. В третьей модели объединены $total_rooms$, $households$ и их отношение $rooms_per_household = total_rooms/household$. Это создаёт строгую функциональную связь, что проявляется как мультиколлинеарность: модель 3 не превосходит модель 2, а отдельные коэффициенты нестабильны.

4. **Что означает коэффициент детерминации R^2?**
   Доля дисперсии целевой переменной, объясняемая регрессионной моделью. $R^2 = 1$ — идеальное описание, $R^2 = 0$ — модель не лучше среднего значения. В работе лучше модель 2 с $R^2 \approx 0.54$.

5. **Зачем нужно разделение на обучающую и тестовую выборки?**
   Чтобы оценить качество модели на данных, которые не использовались при обучении, и выявить переобучение. Деление 80%/20% (13 600/3 400 записей).

6. **Что делает нормировка (стандартизация) признаков?**
   Приводит признаки к сравнимому масштабу (вычет среднего, деление на стандартное отклонение), что упрощает интерпретацию коэффициентов и устойчивость вычислений. Целевая переменная не нормировалась.

7. **Какой признак оказал наибольшее влияние на стоимость жилья?**
   Доход населения ($median_income$) — сильнейший отдельный фактор ($R^2 \approx 0.50$ в модели 1). Добавление возраста дома повысило качество до $R^2 \approx 0.54$ (модель 2).

8. **Почему синтетический признак не улучшил модель 3?**
   Признак $rooms_per_household$ линейно зависит от $total_rooms$ и $households$, поэтому при их совместном включении возникает мультиколлинеарность, и качество не растёт ($R^2 \approx 0.52 < 0.54$ модели 2).

9. **Какие статистики были вычислены по датасету?**
   Количество записей (17 000), среднее, стандартное отклонение, минимум, максимум, квантили 25%, 50% (медиана), 75% для всех девяти признаков.

10. **Какие библиотеки использовались в реализации?**
    Только NumPy и Pandas (загрузка данных, работа с массивами); коэффициенты регрессии вычислены собственным кодом через матричные операции NumPy, готовые средства линейной регрессии не применялись.