ИТМО

Факультет Программной Инженерии и Компьютерной техники

ЛАБОРАТОРНАЯ РАБОТА 4. МЕТОД К-БЛИЖАЙШИХ СОСЕДЕЙ

Аннотация – На исходных данных о вине выполнена предобработка, получена описательная статистика и 3D-визуализация признаков. Реализован метод k-ближайших соседей собственным кодом на Python (NumPy, Pandas) без готовых библиотек классификации. Построены две модели k-NN (случайный и фиксированный наборы признаков), проведена оценка на тестовой выборке при различных k с построением матриц ошибок.

Ключевые слова: k-ближайших соседей, классификация, датасет о вине, NumPy, матрица ошибок

Выполнили

Ануфриев А.С. 465029

Проверил

Болдырева Е. А.

07.11.2026

1 Цели и задачи

Цель работы — исследование и применение метода k-ближайших соседей (k-NN) для классификации winetime-датасета о вине. Основные задачи:

1. получить и визуализировать описательную статистику по датасету (количество, среднее, стандартное отклонение, минимум, максимум, квантили);
2. выполнить предобработку данных: обработку отсутствующих значений, кодирование категориальных признаков, масштабирование;
3. построить 3D-визуализацию признаков;
4. реализовать метод k-ближайших соседей собственным кодом без использования готовых библиотек классификации (только NumPy и Pandas);
5. построить две модели k-NN: со случайным и с фиксированным наборами признаков;
6. оценить каждую модель на тестовой выборке при различных k и построить матрицы ошибок.

2 Исходные данные

Исходный датасет содержит 178 записей о вине. Признаков: 13 числовых (Alcohol, Malic Acid, Ash, Alcalinity of ash, Magnesium, Total phenols, Flavanoids, Nonflavanoid phenols, Proanthocyanins, Color intensity, Hue, OD280/OD315 of diluted wines, Proline). Целевая переменная — Wine (три класса: 1, 2, 3). Пропущенных значений и категориальных признаков в данных не обнаружено.

3 Теоретические сведения

Метод k-ближайших соседей относит объект к классу, наиболее часто встречающемуся среди k ближайших соседей в пространстве признаков. Расстояние между объектами вычисляется по правилу Евклида:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{p=1}^{P} (x_{ip} - x_{jp})^2}. \tag{1}$$

Класс объекта определяется majoritaire голосованием среди k ближайших обучающих примеров. Качество классификации оценивается долей верных предсказаний (accuracy) и матрицей ошибок.

4 Ход работы

4.1 Предобработка данных

В данных отсутствуют пропущенные значения и категориальные признаки. Все 13 числовых признаков подвергнуты стандартизации (вычет среднего, деление на стандартное отклонение). Данные разделены на обучающую (142 записи, 80%) и тестовую (36 записей, 20%) выборки с фиксированным зерном случайности для воспроизводимости.

4.2 Реализация метода k-NN

Метод k-ближайших соседей реализован собственным кодом на Python с использованием NumPy: парные евклидовые расстояния вычисляются матрично, за ним folgt сортировка и выбор k ближайших соседей, класс определяется голосованием. Готовые средства классификации не использовались.

4.3 Модели

Построены две модели (зерно случайности random_state = 42 для воспроизводимости):

- Модель 1 — признаки отбираются случайно (5 из 13: Alcohol, Color intensity, OD280/OD315 of diluted wines, Proanthocyanins, Total phenols);
- Модель 2 — фиксированный набор признаков, выбранный заранее (Alcohol, Malic Acid, Ash, Alcalinity of ash, Magnesium, Total phenols).

Для каждой модели оценка проведена при k = 3, 5, 10, 15.

5 Результаты

5.1 Описательная статистика

Получена описательная статистика по всем признакам (таблица 1), построены гистограммы распределения признаков (рисунок 1) и средние значения признаков (рисунок 2). Для наглядности выполнена 3D-визуализация первых трёх признаков, окрашенная по классам (рисунок 3).

Таблица 1: Описательная статистика по датасету.

Признак	count	mean	std	min	q25	q50	q75	max
Alcohol	178	13.00	0.81	11.03	12.36	13.05	13.68	14.83
Malic Acid	178	2.34	1.12	0.74	1.60	1.87	3.08	5.80
Ash	178	2.37	0.27	1.36	2.21	2.36	2.56	3.23
Alcalinity of ash	178	19.50	3.34	10.60	17.20	19.50	21.50	30.00
Magnesium	178	99.74	14.28	70.00	88.00	98.00	107.00	162.00
Total phenols	178	2.30	0.63	0.98	1.74	2.36	2.80	3.88
Flavanoids	178	2.03	1.00	0.34	1.21	2.14	2.88	5.08

Таблица 2: Описательная статистика по датасету (продолжение).

Признак	count	mean	std	min	q25	q50	q75	max
Nonflavanoid phenols	178	0.36	0.12	0.13	0.27	0.34	0.44	0.66
Proanthocyanins	178	1.59	0.57	0.41	1.25	1.56	1.95	3.58
Color intensity	178	5.06	2.32	1.28	3.22	4.69	6.20	13.00
Hue	178	0.96	0.23	0.48	0.78	0.97	1.12	1.71
OD280/OD315 of diluted wines	178	2.61	0.71	1.27	1.94	2.78	3.17	4.00
Proline	178	746.89	314.91	278.00	500.50	673.50	985.00	1680.00

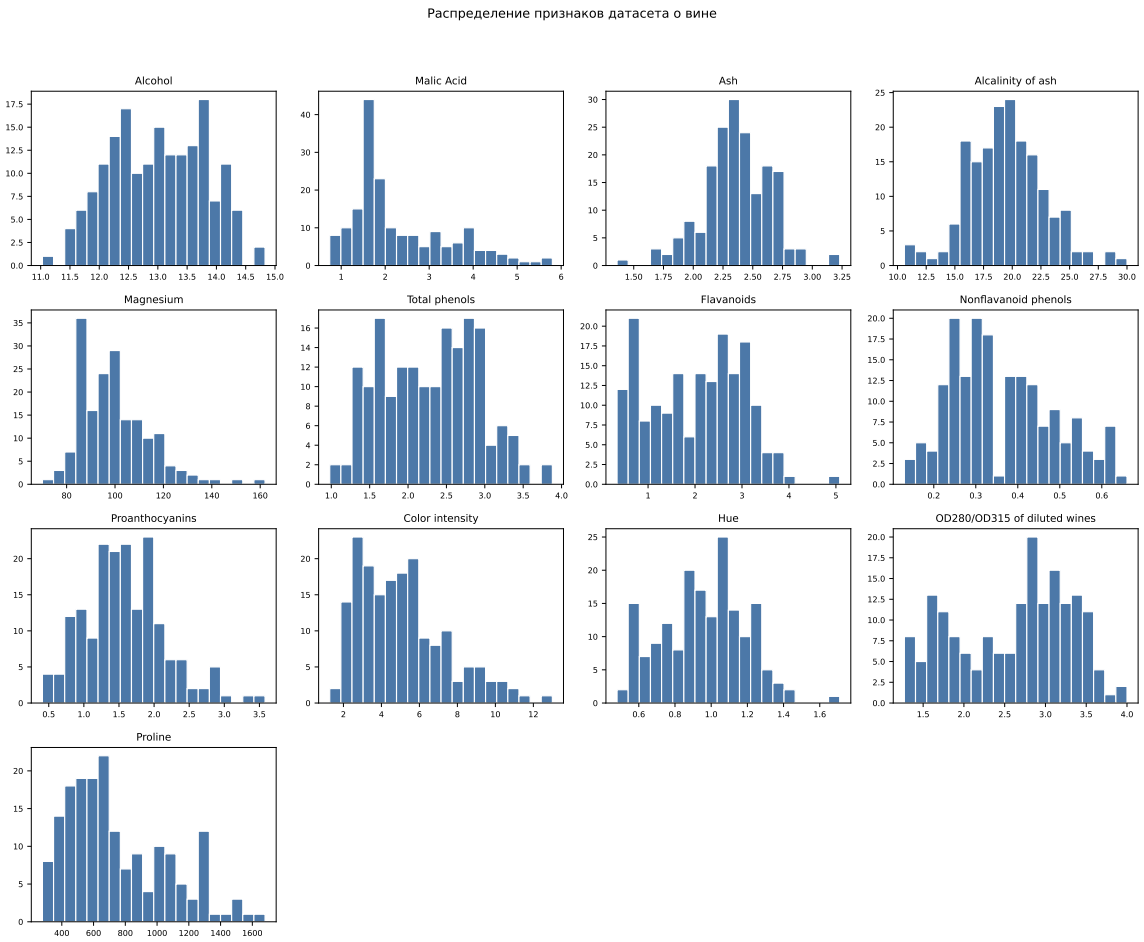


Рис. 1: Распределение признаков датасета о вине.

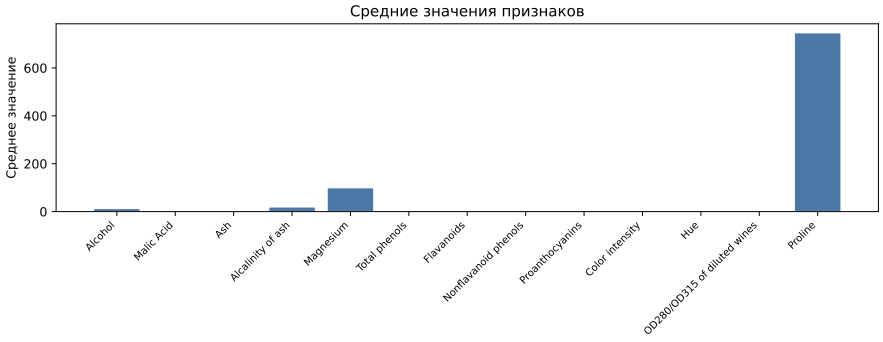


Рис. 2: Средние значения признаков.

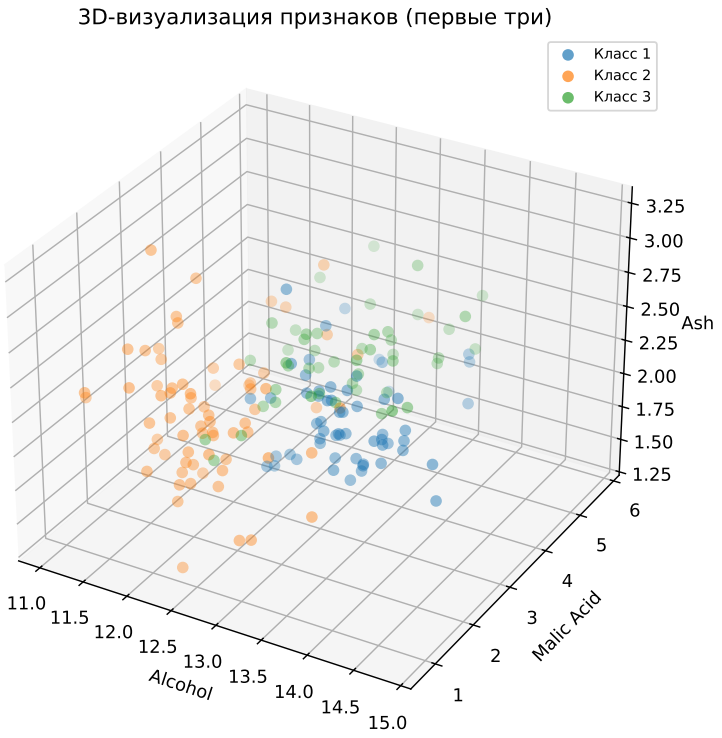


Рис. 3: 3D-визуализация признаков (первые три), окрашенная по классам.

5.2 Качество классификации

Точность классификации (accuracy) на тестовой выборке при различных k приведена в таблице 3.

Таблица 3: Точность k-NN на тестовой выборке.

Модель	Признаки	k=3	k=5	k=10	k=15
Модель 1	случайные (5 признаков)	0.9444	0.9444	0.9167	0.9167
Модель 2	фиксированные (6 признаков)	0.8889	0.8889	0.9444	0.9444

5.3 Матрицы ошибок

Матрицы ошибок для всех пар модель × k на тестовой выборке (строки — истинные классы 1, 2, 3; столбцы — предсказанные классы 1, 2, 3; в каждой ячейке элементы строки матрицы перечислены через “; ”):

Таблица 4: Матрицы ошибок k-NN на тестовой выборке.

Модель	k	Точность	Матрица, строка 1	строка 2	строка 3
Модель 1	3	0.9444	14; 0; 0	1; 12; 1	0; 0; 8
Модель 1	5	0.9444	14; 0; 0	1; 12; 1	0; 0; 8
Модель 1	10	0.9167	14; 0; 0	1; 11; 2	0; 0; 8
Модель 1	15	0.9167	14; 0; 0	1; 11; 2	0; 0; 8
Модель 2	3	0.8889	12; 0; 2	1; 12; 1	0; 0; 8
Модель 2	5	0.8889	13; 0; 1	0; 12; 2	0; 1; 7
Модель 2	10	0.9444	13; 0; 1	0; 14; 0	0; 1; 7
Модель 2	15	0.9444	13; 0; 1	1; 13; 0	0; 0; 8

Матрицы ошибок для каждой модели при k, дающем наилучшую точность (таблица 5 и таблица 6).

Таблица 5: Матрица ошибок, Модель 1, k=5.

	Предсказанный класс		
Истинный класс	1	2	3
1	14	0	0
2	1	12	1
3	0	0	8

Таблица 6: Матрица ошибок, Модель 2, k=10.

	Предсказанный класс		
Истинный класс	1	2	3
1	13	0	1
2	0	14	0
3	0	1	7

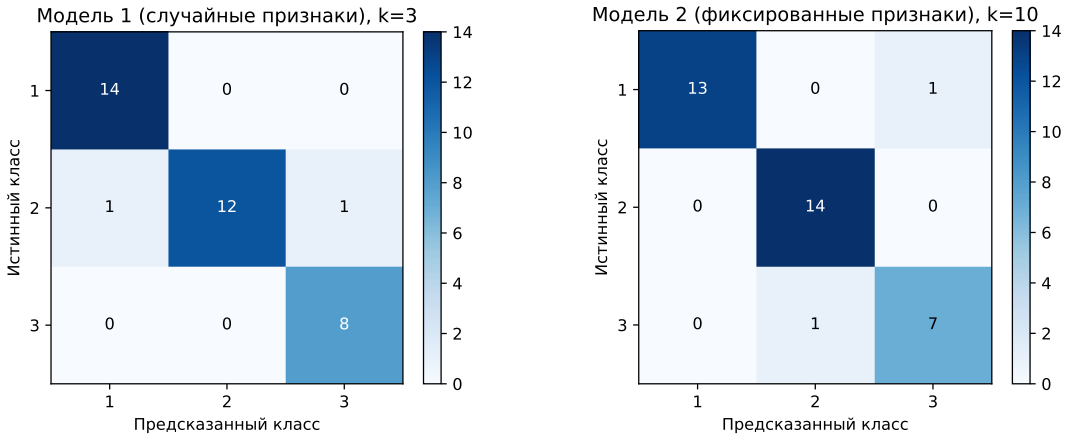


Рис. 4: Матрицы ошибок: Модель 1 (слева, k=5) и Модель 2 (справа, k=10).

6 Выводы

Реализован метод k-ближайших соседей без готовых библиотек классификации. Обе модели обеспечивают высокую точность на тестовой выборке (до 0.9444). Модель 1 с случайным набором признаков стабильна при k=3 и k=5 (0.9444), Модель 2 с фиксированным набором достигает наилучшего результата при k=10 и k=15 (0.9444). Матрицы ошибок показывают, что основные ошибки приходятся на путаницу между классами 2 и 3.

7 Приложение

Полный фрагмент реализации метода k-ближайших соседей (NumPy). X и y — признаки и метки классов после загрузки и предобработки датасета (стандартизация: вычет среднего, деление на стандартное отклонение); random_state = 42.

```
import numpy as np

rng = np.random.RandomState(42)
n = X.shape[0]
idx = rng.permutation(n)
n_test = int(round(0.2 * n))
train_idx, test_idx = idx[n_test:], idx[:n_test]
X_tr, X_te = X[train_idx], X[test_idx]
y_tr, y_te = y[train_idx], y[test_idx]

class KNN:
    def __init__(self, k=3):
        self.k = k
    def fit(self, X, y):
        self.X = np.asarray(X, float); self.y = np.asarray(y)
    def predict(self, X):
        X = np.asarray(X, float)
        a2 = np.sum(X**2, axis=1, keepdims=True)
        b2 = np.sum(self.X**2, axis=1, keepdims=True).T
        ab = X @ self.X.T
        d = np.sqrt(np.maximum(a2 + b2 - 2*ab, 0.0))
        nb = np.argsort(d, axis=1)[:, :self.k]
        return np.array([np.bincount(self.y[nb[i]].astype(int)).argmax()
                         for i in range(X.shape[0])])

def accuracy(y_true, y_pred):
    return float(np.mean(y_true == y_pred))

for k in (3, 5, 10, 15):
    clf = KNN(k=k)
    clf.fit(X_tr, y_tr)
    print(k, accuracy(y_te, clf.predict(X_te)))
```

8 Литература

1. Лабораторное задание №4. Метод k-ближайших соседей.
2. Датасет о вине WineDataset.csv (исходные данные).
3. NumPy — библиотека для научных вычислений на языке Python.
4. Pandas — библиотека для анализа и обработки данных.