Теория лабораторной работы 4. Метод k-ближайших соседей: вопросы защиты и ответы

Ануфриев А.С. 465029

07.11.2026

1 Теоретические сведения

Метод k-ближайших соседей (k-NN) — один из простейших методов надзоруемой классификации. Объект относится к классу, который наиболее часто встречается среди k ближайших соседей в пространстве признаков. Мера близости обычно — евклидово расстояние:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{p=1}^{P} (x_{ip} - x_{jp})^2}. \tag{1}$$

Параметр k определяет соседей, участвующих в голосовании: малое k делает модель чувствительной к шуму, большое k — более устойчивой, но может сглаживать границы классов. k-NN не требует обучения в классическом смысле (ленивый алгоритм): все вычисления выполняются на этапе предсказания. Перед применением признаки масштабируются (стандартизация иначе признаки с большими значениями доминируют в расстоянии. Качество оценивается точностью (accuracy) и матрицей ошибок.

2 Вопросы защиты и ответы

2.1 Что такое метод k-ближайших соседей и к какому классу задач он относится?

k-NN — метод надзоруемой классификации (и регрессии), опирающийся на расстояния в пространстве признаков. Объект классифицируется по классу большинства среди k ближайших обучающих примеров.

2.2 Как выбирается параметр k?

k выбирается экспериментально (кросс-валидация). Малое k — чувствительность к шуму и выбросам, большое k — размытие границ классов. В работе рассматривались k = 3, 5, 10, 15.

2.3 Какая метрика расстояния использовалась и почему?

Евклидово расстояние — стандартная метрика для k-NN на числовых признаках. Оно адекватно измеряет близость после стандартизации признаков.

2.4 Зачем нужна стандартизация признаков перед k-NN?

Признаки имеют разные размерности и диапазоны (например, Alcohol 13, Proline 747). Без масштабирования признаки с большими абсолютными значениями доминируют в расстоянии, искажая результат.

2.5 Чем отличаются Модель 1 и Модель 2?

Модель 1 использует случайный набор признаков (5 из 13), Модель 2 — фиксированный набор, выбранный заранее (6 признаков). Это позволяет оценить влияние состава признаков на качество классификации.

2.6 Что показывает матрица ошибок?

Матрица ошибок распределяет предсказания по истинным и предсказанным классам. Диагональ — верные предсказания, внедиагональные элементы — ошибки классификации между конкретными классами.

2.7 Почему ошибки классификации в работе приходятся mainly на классы 2 и 3?

Классы 2 и 3 ближе друг к другу в пространстве признаков, чем класс 1, что затрудняет их раздел k-NN и приводит к путанице между ними.

2.8 Какие библиотеки использовались при реализации k-NN?

Только NumPy и Pandas (для линейной алгебры и работы с данными). Готовые средства классификации (sklearn и т.п.) не применялись.

2.9 Какое качество показали модели?

На тестовой выборке (36 записей) обе модели достигают точности до 0.9444. Модель 1: k=3,5 — 0.9444; k=10,15 — 0.9167. Модель 2: k=3,5 — 0.8889; k=10,15 — 0.9444.