ИТМО

Факультет Программной Инженерии и Компьютерной техники

ЛАБОРАТОРНАЯ РАБОТА №5. ДЕРЕВО РЕШЕНИЙ ДЛЯ КЛАССИФИКАЦИИ ГРИБОВ

Аннотация – Построено небинарное дерево решений для бинарной классификации грибов (съедобный / ядовитый) на датасете UCI Mushroom без использования сторонних библиотек для построения дерева и оценки качества. Отобраны случайным образом $\sqrt{n}$ признаков, реализованы метрики Accuracy, precision, recall и кривые AUC-ROC и AUC-PR. Приведены результаты на тестовой выборке.

Ключевые слова: дерево решений, бинарная классификация, грибы, AUC-ROC, AUC-PR, Python, NumPy

Выполнили

Ануфриев А.С. 465029

Проверил

Болдырева Елена Александровна

08.11.2026

1 Цель и задачи работы

Целью работы является реализация алгоритма построения дерева решений для задачи бинарной классификации грибов (съедобный / ядовитый) на датасете UCI Mushroom и оценка его качества. Основные этапы:

1. загрузка и предобработка исходных данных;
2. случайный отбор $\sqrt{n}$ признаков;
3. построение небинарного дерева решений собственным кодом без сторонних библиотек для построения дерева;
4. оценка по Accuracy, precision и recall без использования библиотек;
5. построение кривых AUC-ROC и AUC-PR без использования библиотек.

2 Исходные данные

Используется датасет UCI Mushroom с классификацией грибов (файл *agaricus-lepiota.data*; семейства *Agaricus* и *Lepiota*, источник — справочник *The Audubon Society Field Guide to North American Mushrooms*, 1981). Датасет содержит 8124 объекта, каждый описывается классом (съедобный `e` / ядовитый `p`) и 22 номинативными признаками (форма шляпки, запах, цвет спорового порошка и т.д.). Все признаки имеют дискретное множество значений; пропуски обозначены "?", встречаются только в признаке "stalk-root".

После удаления объектов с пропусками остаётся 5644 записи: 3488 съедобных (61.8%) и 2156 ядовитых (38.2%).

3 Метод: дерево решений

Построение дерева выполняется рекурсивно сверху вниз (подход алгоритма C4.5). В каждом узле выбирается признак с максимальным нормированным приростом информации:

$$\text{GainRatio}(X) = \frac{\text{Info}(T) - \text{Info}_X(T)}{\text{splitinfo}(X)},$$

где $\text{Info}(T) = -\sum_j p_j \log_2 p_j$ — энтропия множества примеров T, $\text{Info}_X(T) = \sum_i \frac{|T_i|}{|T|}\text{Info}(T_i)$ — условная энтропия после разбиения по признаку X, $\text{splitinfo}(X) = -\sum_i \frac{|T_i|}{|T|}\log_2\frac{|T_i|}{|T|}$. По выбранному признаку создаются столько потомков, сколько у него значений (дерево не бинарное). Рекурсия продолжается до исчерпания примеров в узле, достижения максимальной глубины или нулевого прироста информации. Лист получает класс большинства объектов в узле. Дерево реализовано через класс узла со ссылками на потомков (список-списков не используется).

4 Ход работы

1. Чтение исходных данных; исключение записей с пропущенными значениями в признаке "stalk-root".
2. Случайный отбор $\sqrt{22} \approx 4$ признаков с фиксированным зерном генератора: *cap-shape*, *cap-surface*, *gill-color*, *stalk-color-above-ring*.

3. Стратифицированное разделение на обучающую (70%) и тестовую (30%) выборки: 3951 и 1693 объекта соответственно, соотношение классов сохранено.

4. Построение дерева на обучающей выборке: глубина 4, 85 внутренних узлов, 63 листа.

5. Получение меток классов и вероятностей (доля ядовитых в листе) для объектов тестовой выборки.

6. Расчёт Accuracy, precision, recall, построение кривых AUC-ROC и AUC-PR собственным кодом без библиотек.

5 Результаты

Таблица 1 содержит элементы матрицы ошибок и качество классификации на тестовой выборке (положительный класс — ядовитый гриб).

Таблица 1: Матрица ошибок и метрики качества на тестовой выборке (1693 объекта).

Значение			
TP (яды распознаны)	472	FP (съедобные как яды)	71
TN (съедобные распознаны)	975	FN (яды как съедобные)	175
Accuracy			0.8547
Precision			0.8692
Recall			0.7295
AUC-ROC			0.9416
AUC-PR			0.9223

Дерево даёт высокую точность (85.5%) и высокую AUC-ROC (0.9416). При этом recall 0.7295 означает, что часть ядовитых грибов классифицируется как съедобные, что для задачи безопасного потребления является ограничением.

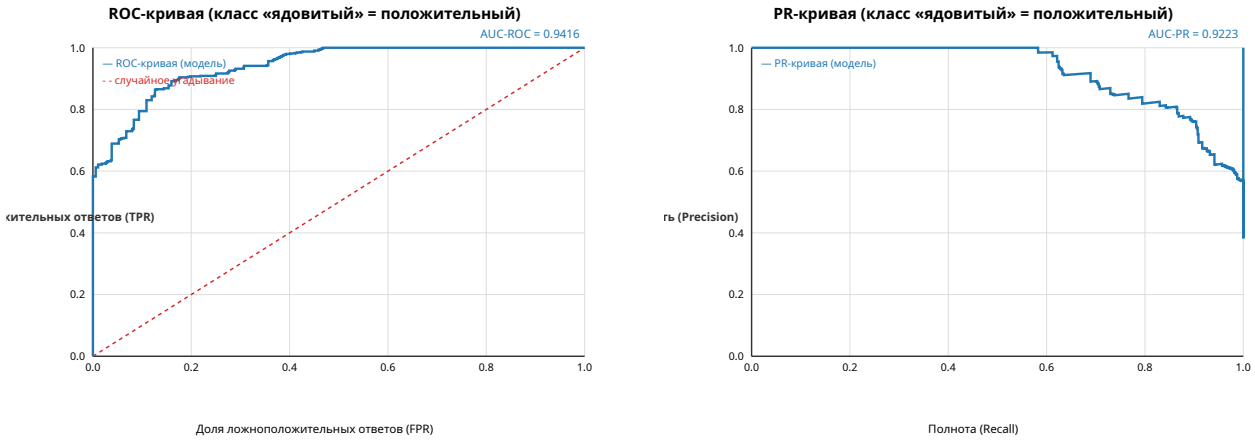


Рис. 1: Контрольные кривые качества классификатора на тестовой выборке: ROC-кривая (AUC-ROC = 0.9416) и PR-кривая (AUC-PR = 0.9223). Построены из фактических данных тестовой выборки.

6 Выводы

Реализовано небинарное дерево решений для бинарной классификации грибов без сторонних библиотек. На отобранных случайным образом 4 признаках дерево глубины 4 достигает Accuracy 0.8547, precision 0.8692 и recall 0.7295 на тестовой выборке; AUC-ROC = 0.9416, AUC-PR = 0.9223. Получение вероятностей классов из долей объектов в листьях позволяет построить ROC- и PR-кривые и компактно оценить всю область порогов принятия решений.

7 Список литературы

1. Schlimmer, J.C. (1987). Concept Acquisition Through Representational Adjustment. Technical Report 87-19, Department of Information and Computer Science, University of California, Irvine. (Donor of the UCI Mushroom dataset.)

2. Aha, D.W. (1988). Comments on the Mushroom Database. University of California, Irvine.

3. Quinlan, J.R. (1993). C4.5: Programs for Machine Learning. Morgan Kaufmann, San Mateo, CA.

4. Lincoff, G.H. (1981). The Audubon Society Field Guide to North American Mushrooms. Alfred A. Knopf, New York.

8 Приложение

Исходные параметры эксперимента: фиксированное зерно генератора 42; отбор $\sqrt{n}$ признаков (4 из 22); стратифицированное разбиение 70/30; критерий разбиения — нормированный прирост информации (C4.5); максимальная глубина 12 (достигнута 4); остановка при чистом узле, отсутствии прироста или исчерпании признаков. Реализация выполнена на Python с использованием NumPy; построение дерева, расчёт метрик и кривых выполнены собственным кодом без сторонних библиотек.

Положительный класс в дальнейшем — ядовитый гриб (`p`); отрицательный — съедобный (`e`).

Расчёт кривых AUC-ROC и AUC-PR: объекты тестовой выборки сортируются по убыванию оценки вероятности класса “ядовитый” (доля таких объектов в листе дерева). При каждом пороге вычисляются $TPR = TP/(TP+FN)$, $FPR = FP/(FP+TN)$ — точки ROC-кривой, и $Precision = TP/(TP+FP)$, $Recall = TP/(TP+FN)$ — точки PR-кривой. Площадь под кривыми считается методом трапеций по отсортированным точкам; начальные точки $(0,0)$ и $(1,1)$ (ROC) и $(0,1)$ (PR) добавляются явно. Все расчёты — собственные, без библиотек.

Таблица 2 содержит точки работы классификатора (порог вероятности, FPR, TPR, precision, recall) при всех distintos значениях вероятности на тестовой выборке; по ним можно воспроизвести значения AUC-ROC = 0.9416 и AUC-PR = 0.9223.

Таблица 2: Точки работы классификатора по порогам вероятности класса «ядовитый» (тестовая выборка, 1693 объекта).

Порог	FPR	TPR	Precision	Recall
1.000000	0.000000	0.582689	1.000000	0.582689
0.782609	0.010516	0.621329	0.973366	0.621329
0.600000	0.041109	0.689335	0.912065	0.689335
0.534884	0.067878	0.729521	0.869245	0.729521
0.461538	0.083174	0.766615	0.850772	0.766615
0.438596	0.108987	0.829985	0.824885	0.829985
0.432432	0.119503	0.842349	0.813433	0.842349
0.344444	0.153920	0.877898	0.779150	0.877898
0.333333	0.159656	0.891808	0.775538	0.891808
0.277778	0.178776	0.904173	0.757772	0.904173
0.240000	0.191205	0.904173	0.745223	0.904173
0.220588	0.224665	0.908810	0.714459	0.908810
0.206522	0.250478	0.916538	0.693567	0.916538
0.196078	0.318356	0.941267	0.646497	0.941267
0.189189	0.356597	0.956723	0.623992	0.956723
0.180000	0.380497	0.969088	0.611707	0.969088
0.171717	0.380497	0.970634	0.612086	0.970634
0.150000	0.411090	0.981453	0.596244	0.981453
0.137931	0.450287	0.987635	0.575676	0.987635
0.000000	1.000000	1.000000	0.382162	1.000000

Остановка рекурсии дерева: все объекты в узле одного класса, нулевой прирост информации, исчерпание признаков или достижение максимальной глубины 12 (фактическая глубина построенного дерева — 4).