Лабораторная работа №5. Теория и вопросы защиты: дерево решений для классификации грибов

Ануфриев А.С. 465029

08.11.2026

1 Деревья решений

Дерево решений — иерархическая структура, представляющая правила классификации в виде последовательности проверок. Каждый внутренний узел содержит проверку по какому-то признаку, ребра соответствуют возможным значениям признака, а листья содержат метки классов. Каждый объект попадает в единственный лист, что даёт покрывающий набор конъюнкций. Классы должны быть дискретными, каждый пример относится к одному классу однозначно.

2 Алгоритм C4.5

Алгоритм C4.5 строит небинарное дерево (количество потомков узла не ограничено) и решает задачи классификации. Работа происходит итеративно сверху вниз:

1. изначально все примеры ассоциированы с корнем;
2. выбирается признак для проверки, множество разбивается на подмножества по значениям признака, для каждого создаётся потомок;
3. процесс рекурсивно повторяется для каждого подмножества до остановки.

Количество классов должно быть значительно меньше количества записей.

2.1 Критерий разбиения

Пусть T — множество примеров, $freq(C_j, T)$ — число примеров класса C_j. Энтропия (средняя информация для определения класса):

$$Info(T) = -\sum_{j=1}^{k} \frac{freq(C_j, T)}{|T|} \log_2 \frac{freq(C_j, T)}{|T|}.$$

После разбиения по проверке X со значениями $A_1, \ldots, A_n$, дающем подмножества T_i:

$$Info_X(T) = \sum_{i=1}^{n} \frac{|T_i|}{|T|} Info(T_i), \qquad splitinfo(X) = -\sum_{i=1}^{n} \frac{|T_i|}{|T|} \log_2 \frac{|T_i|}{|T|}.$$

Нормированный прирост информации:

$$GainRatio(X) = \frac{Info(T) - Info_X(T)}{splitinfo(X)}.$$

На каждом шаге выбирается признак с максимальным $GainRatio$.

3 Реализация без сторонних библиотек

Дерево реализуется через узел со ссылками на потомка по каждому значению признака (не список-списков). В узле хранятся индекс признака-разделителя и словарь "значение признака → дочерний узел". Лист хранит класс большинства и долю объектов положительного класса, которая используется как вероятность предсказания. Остановка рекурсии: все примеры в узле одного класса, отсутствие прироста информации, исчерпание признаков или достижение максимальной глубины.

4 Метрики качества бинарной классификации

Пусть объект относится к положительному классу (ядовитый гриб). Матрица ошибок: TP (истинноположительные), FP (ложноположительные), TN (истинноотрицательные), FN (ложноотрицательные). Тогда:

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN}, \qquad Precision = \frac{TP}{TP + FP}, \qquad Recall = \frac{TP}{TP + FN}.$$

Все метрики вычисляются собственным кодом без библиотек.

5 Кривые AUC-ROC и AUC-PR

При изменении порога принятия решения строятся пары (FPR, TPR), где $TPR = TP/(TP + FN)$ и $FPR = FP/(FP + TN)$ — это ROC-кривая; площадь под ней — AUC-ROC. Пара $(Recall, Precision)$ даёт PR-кривую, её площадь — AUC-PR. Площади считаются методом трапеций по отсортированным по убыванию вероятностей точкам. Обе кривые и значения AUC вычисляются без сторонних библиотек.

6 Вероятные вопросы защиты с ответами

1. *Что представляет собой дерево решений и какую задачу оно решает?* Ответ: иерархическая структура правил классификации; узлы — проверки признаков, ребра — значения признаков, листья — классы; решает задачи классификации с дискретными классами.

2. *Чем алгоритм C4.5 отличается от бинарных деревьев?* Ответ: количество потомков узла не ограничено, каждое значение признака порождает отдельного потомка.

3. *По какому критерию выбирается признак для разбиения узла?* Ответ: по максимальному нормированному приросту информации $GainRatio(X)$.

4. *Как считается энтропия множества примеров?* Ответ: $Info(T) = -\sum_j p_j \log_2 p_j$, где p_j — доля примеров класса C_j.

5. *Что делает множитель splitinfo в gain ratio?* Ответ: корректирует прирост информации, снижая преимущество признаков с большим числом уникальных значений.

6. *Почему в данных были исключены niektóre записи?* Ответ: в признаке "stalk-root" встречаются пропуски "?", такие объекты удалены перед обучением.

7. *Сколько признаков использовалось и как они выбирались?* Ответ: $\sqrt{22} \approx 4$ признака, отобранных случайным образом с фиксированным зерном генератора.

8. *Как вычислялись Accuracy, precision и recall?* Ответ: по формулам из матрицы ошибок, собственным кодом без библиотек.

9. *Что такое AUC-ROC и AUC-PR и как они вычислялись?* Ответ: площади под ROC- и PR-кривыми, построенными по парам (FPR, TPR) и (Recall, Precision) при разных порогах; площадь считается методом трапеций, без библиотек.

10. *Какое качество достигнуто на тестовой выборке?* Ответ: Accuracy 0.8547, precision 0.8692, recall 0.7307, AUC-ROC 0.9406, AUC-PR 0.9223.