ИТМО

Факультет Программной Инженерии и Компьютерной техники

ЛАБОРАТОРНАЯ РАБОТА №6. ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ — ТЕОРИЯ И ВОПРОСЫ ЗАЩИТЫ

Аннотация – Теоретические сведения по логистической регрессии и ответы на вероятные вопросы защиты лабораторной работы: математическая форма модели, функция потерь, алгоритмы обучения, метрики классификации и исследование гиперпараметров на примере датасета пассажиров Титаника.

Ключевые слова: логистическая регрессия, сигмоида, log-loss, градиентный спуск, метод Ньютона, метрики классификации

Выполнили

Ануфриев А.С. 465029

Проверил

Болдырева Елена Александровна

08.11.2026

1 Теоретические сведения

1.1 Постановка задачи

Логистическая регрессия предназначена для бинарной классификации. Каждому объекту ставится в соответствие метка $y \in \{0, 1\}$. Модель оценивает вероятность принадлежности объекта к положительному классу:

$$P(y = 1 \mid x) = \sigma(z), \qquad z = x^T w, \tag{1}$$

где w — вектор параметров модели (включая свободный член), x — вектор признаков объекта, $\sigma(\cdot)$ — сигмоидная функция.

1.2 Сигмоидная функция

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \qquad \sigma'(z) = \sigma(z)(1 - \sigma(z)). \tag{2}$$

Функция σ монотонно возрастает, её значения лежат на отрезке $(0, 1)$, что позволяет интерпретировать выход модели как вероятность. Порог классификации обычно принимается равным 0.5: объект относится к классу 1, если $p \geq 0.5$, и к классу 0 в противном случае.

1.3 Функция потерь

Для обучения используется функция логарифмических потерь (log-loss, кросс-энтропия):

$$L(w) = -\frac{1}{N} \sum_{i=1}^{N} \Big[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \Big], \tag{3}$$

где $p_i = \sigma(x_i^T w)$ — предсказанная вероятность для i-го объекта. Функция выпукла по параметрам w, поэтому градиентные методы сходятся к глобальному минимуму.

1.4 Градиентный спуск

Градиент функции потерь по параметрам:

$$\nabla_w L = \frac{1}{N} X^T (p - y), \tag{4}$$

где X — матрица признаков со столбцом смещения, p и y — векторы предсказанных вероятностей и истинных меток. Обновление весов:

$$w \leftarrow w - \eta \nabla_w L, \tag{5}$$

где η — скорость обучения (learning rate). Выбор η влияет на скорость сходимости и стабильность: слишком большое η может привести к дивергенции, слишком маленькое — к медленной сходимости.

1.5 Оптимизация Ньютона

Вместо градиентного спуска можно использовать метод Ньютона (второй порядок). Гессиан функции потерь:

$$H = \frac{1}{N} X^T W X, \tag{6}$$

где W — диагональная матрица с элементами $p_i(1 - p_i)$ на диагонали. Обновление:

$$w \leftarrow w - H^{-1} \nabla_w L. \tag{7}$$

Метод Ньютона обычно сходится за меньшее число итераций, но требует обращения (или решения линейной системы) с матрицей размером $(d + 1) \times (d + 1)$, где d — число признаков, что дороже по вычислениям на каждой итерации.

1.6 Метрики классификации

Построим матрицу ошибок на тестовой выборке:

- TP — истинно положительные (выжили, предсказано выжили);
- TN — истинно отрицательные (не выжили, предсказано не выжили);
- FP — ложноположительные (не выжили, предсказано выжили);
- FN — ложноотрицательные (выжили, предсказано не выжили).

Тогда:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \tag{8}$$

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN}, \qquad \text{F1-Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \tag{9}$$

Accuracy измеряет общую долю верных ответов. Precision — долю верно предсказанных выживших среди всех, кому модель предсказала выживание. Recall — долю реально выживших, которые модель верно обнаружила. F1-Score — гармоническое среднее precision и recall, устойчивое к désbalanscy классов.

2 Вероятные вопросы защиты с ответами

Вопрос 1. В чём отличие логистической регрессии от линейной?

Ответ. Линейная регрессия предсказывает непрерывное числовое значение и minimизирует среднеквадратичную ошибку. Логистическая регрессия предназначена для классификации: через сигмоиду она выдаёт вероятность принадлежности к классу в интервале $(0, 1)$, а функцией потерь служит кросс-энтропия (log-loss). Порог 0.5 превращает вероятность в класс 0 или 1.

Вопрос 2. Зачем нужна сигмоида и какова её производная?

Ответ. Сигмоида отображает любое действительное число z на отрезок $(0, 1)$, что даёт интерпретацию выхода как вероятности. Её производная $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ используется при вычислении градиента функции потерь и при построении гессиана для метода Ньютона.

Вопрос 3. Как выбирается порог классификации, и что изменится при его сдвиге?

Ответ. Стандартный порог — 0.5. Повышение порога снижает число ложноположительных ответов (растёт precision) и увеличивает число ложноотрицательных (падает recall). Понижение порога действует наоборот. Выбор порога зависит от задачи: например, при скрининге важнее recall, при целевой рассылке — precision.

Вопрос 4. Как обрабатывались пропуски в датасете Титаника?

Ответ. Пропуски в возрасте (*Age*) и стоимости билета (*Fare*) заполнены медианными значениями, пропуски в порту посадки (*Embarked*) — модальным. Признак *Cabin* с большим числом пропусков исключён из модели. Категориальные признаки закодированы числовыми значениями, числовые признаки стандартизированы.

Вопрос 5. Какое влияние оказывает скорость обучения на обучение модели?

Ответ. Маленькая скорость обучения обеспечивает стабильную, но медленную сходимость. Большая скорость ускоряет сходимость на начальных этапах, но может вызывать колебания весов и дивергенцию, особенно на поздних итерациях. В работе наилучший результат получен при learning rate 0.01; при lr = 0.1 и 0.5 качество на тесте не улучшалось и даже снижалось при длительном обучении.

Вопрос 6. Зачем нужна стандартизация признаков в логистической регрессии?

Ответ. Признаки имеют разные размерности и диапазоны (например, возраст до 80 лет, стоимость билета до 512). Стандартизация приводит их к сравнимому масштабу, что ускоряет сходимость градиентного спуска и делает шаги обновления весов сбалансированными по всем признакам.

Вопрос 7. В чём преимущество и недостаток метода Ньютона по сравнению с градиентным спуском?

Ответ. Метод Ньютона использует вторую производную и обычно требует меньше итераций для сходимости. Недостаток — необходимость обращать матрицу гессиана размера $(d+1) \times (d+1)$ на каждой итерации, что существенно дороже при большом числе признаков. В работе метод Ньютона сходился быстро, но не превзошёл градиентный спуск по точности на тестовой выборке.

Вопрос 8. Как оценивалось качество модели и какая метрика выбрана главной?

Ответ. Качество оценивалось на отдельной тестовой выборке (20% данных) по accuracy, precision, recall и F1-Score. Главной метрикой принят F1-Score, так как он учитывает и precision, и recall и устойчив к désbalanscy классов (выживших меньше, чем не выживших). Наилучший F1-Score 0.7402 получен при градиентном спуске с lr = 0.01 и 1000 итерациями.

Вопрос 9. Что означают значения TP, TN, FP, FN для лучшей модели?

Ответ. Для лучшей комбинации на тестовой выборке: TP = 47 (верно предсказано выживших), TN = 99 (верно предсказано не выживших), FP = 15 (ошибочно предсказано выжившими), FN = 18 (выжившие, ошибочно отнесённые к не выжившим). На основании них вычислены accuracy 0.8156, precision 0.7581, recall 0.7231, F1-Score 0.7402.

Вопрос 10. Можно ли сказать, что логистическая регрессия линейная модель?

Ответ. Да, логистическая регрессия — линейная модель в том смысле, что решение о классе принимается по линейной комбинации признаков $z = x^T w$: сигмоида монотонна, поэтому $p \geq 0.5$ эквивалентно $x^T w \geq 0$, что задаёт линейную границу разделения классов в пространстве признаков.