Теория и вопросы защиты по всем четырём методам модуля 2: линейная регрессия, k-NN, дерево решений, логистическая регрессия

Ануфриев А.С. 465029

08.11.2026

1 Введение

В данном документе собран теоретический материал по четырём методам надзоруемого обучения, изученным в рамках модуля 2 (лабораторные работы №3–№6): линейная регрессия, метод k-ближайших соседей (k-NN), дерево решений и логистическая регрессия. Все методы были реализованы "с нуля" на языке Python с использованием только NumPy и Pandas без готовых библиотек машинного обучения (sklearn и аналоги). Документ предназначен для подготовки к защите: в конце каждого раздела приведены вероятные вопросы с ответами, а в завершении — сравнительный обзор методов.

2 Линейная регрессия (метод наименьших квадратов)

2.1 Суть метода

Линейная множественная регрессия описывает зависимость результативного признака y от p факторов $x_1, \ldots, x_p$ линейной моделью

$$y = a + b_1 x_1 + \cdots + b_p x_p + \varepsilon, \tag{1}$$

где a — свободный член, b_j — регрессионные коэффициенты, ε — случайная ошибка. Эмпирическая оценка:

$$\hat{y} = a + b_1 x_1 + \cdots + b_p x_p. \tag{2}$$

В матричной записи $\hat{Y} = XB$, где в матрицу X добавлен первый столбец единиц для свободного члена.

2.2 Метод наименьших квадратов (МНК)

Оценки параметров получаются минимизацией суммы квадратов остатков

$$Q(B) = \sum_i e_i^2 = (Y - XB)^\top (Y - XB). \tag{3}$$

Дифференцирование по B и приведение производной к нулю даёт нормальное уравнение

$$B = (X^\top X)^{-1} X^\top Y. \tag{4}$$

Это аналитическое (замкнутое) решение: матричные операции одной итерации дают оптимальные коэффициенты при условии обратимости $X^\top X$.

2.3 Качество модели

Коэффициент детерминации

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2} \tag{5}$$

показывает долю дисперсии целевой переменной, объясняемую моделью. $R^2 = 1$ — идеальное описание, $R^2 = 0$ — модель не точнее среднего значения.

2.4 Предположения МНК (теорема Гаусса—Маркова)

1. модель специфицирована верно (зависимость линейна);
2. между факторами нет строгой линейной зависимости (отсутствие мультиколлинеарности);
3. ошибки случайны, их математическое ожидание равно нулю, дисперсия постоянна (гомоскедастичность);
4. ошибки не коррелированы между собой.

При выполнении этих условий оценки МНК являются наилучшими линейными несмещёнными оценками (BLUE).

2.5 Особенности реализации в работе

В лабораторной работе №3 коэффициенты вычислены собственной функцией на NumPy по формуле $B = (X^\top X)^{-1} X^\top Y$ без готовых средств регрессии. Признаки стандартизированы (вычет среднего, деление на стандартное отклонение), целевая переменная не нормировалась. Построено три модели: по доходу (≈ 0.50), по доходу и возрасту дома (≈ 0.54) и с синтетическим признаком $rooms_per_household = total_rooms/households$ (≈ 0.52).

2.6 Преимущества

- простота реализации и интерпретации: каждый коэффициент показывает изменение цели при изменении на единицу соответствующего признака;
- аналитическое решение, нет необходимости в итерационной оптимизации и подборе коэффициента обучения;
- высокая скорость обучения и предсказания;
- хорошая база для сравнения более сложных моделей.

2.7 Недостатки и ограничения

- предполагает линейную зависимость между признаками и целевой переменной;
- чувствительна к мультиколлинеарности (в работе признаки $total_rooms$, $households$ и их отношение создали строгую функциональную связь, что не улучшило модель 3);
- чувствительна к выбросам, так как минимизирует сумму квадратов ошибок;
- не подходит для классовых (дискретных) целей без модификаций.

2.8 Вопросы защиты с ответами

1. **Что такое метод наименьших квадратов и в чём его суть?**
   МНК — способ оценки параметров регрессионной модели, минимизирующий сумму квадратов отклонений наблюдаемых значений от предсказанных моделью. Аналитически решение задаётся формулой $B = (X^\top X)^{-1} X^\top Y$.

2. **Зачем нужен первый столбец единиц в матрице X?**
   Он соответствует свободному члену a — значению y, когда все факторы равны нулю, и позволяет смещать регрессионную плоскость по оси y.

3. **Что означает коэффициент детерминации R^2?**
   Доля дисперсии целевой переменной, объясняемая моделью. Чем ближе к единице, тем лучше. В работе лучшая модель — $R^2 \approx 0.54$.

4. **Зачем нужно разделение на обучающую и тестовую выборки?**
   Чтобы оценить качество модели на данных, не использовавшихся при обучении, и выявить переобучение. В работе — разделение 80/20 (13 600 / 3 400 записей).

5. **Зачем нужна стандартизация признаков?**
   Приводит признаки к сравнимому масштабу, упрощает интерпретацию коэффициентов и устойчивость вычислений.

6. **Что такое мультиколлинеарность и как она проявилась в работе?**
   Строгая линейная зависимость между признаками. В третьей модели $total_rooms$, $households$ и $rooms_per_household = total_rooms/households$ линейно связаны, модель 3 не превзошла модель 2 ($R^2 \approx 0.52 < 0.54$).

7. **Какой признак сильнее всего влияет на стоимость жилья?**
   Доход населения ($median_income$) — сильнейший отдельный фактор ($R^2 \approx 0.50$ в однофакторной модели).

3 Метод k-ближайших соседей (k-NN)

3.1 Суть метода

k-NN — метод надзоруемой классификации (и регрессии). Объект относится к классу, наиболее часто встречающемуся среди k ближайших соседей в пространстве признаков. Расстояние обычно евклидово:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{p=1}^{P} (x_{ip} - x_{jp})^2}. \tag{6}$$

Класс определяется majoritaire голосованием среди k ближайших обучающих примеров. Это “ленивый” алгоритм: явного этапа обучения нет, модель просто хранит обучающую выборку, а все вычисления выполняются на этапе предсказания.

3.2 Выбор параметра k и масштабирование

Параметр k определяет соседей, участвующих в голосовании. Малое k делает модель чувствительной к шуму и выбросам (резкие границы классов), большое k — более устойчивой, но может сглаживать границы и стирать мелкие структуры. Оптимальное k подбирается

экспериментально (например, кросс-валидацией). Перед применением признаки масштабируются (стандартизация), иначе признаки с большими абсолютными значениями доминируют в расстоянии.

3.3 Качество классификации

Оценивается долей верных предсказаний (accuracy) и матрицей ошибок: строки — истинные классы, столбцы — предсказанные; диагональ — верные ответы, внедиагональные элементы — ошибки между конкретными классами.

3.4 Особенности реализации в работе

В лабораторной работе №4 k-NN реализован на NumPy: парные евклидовые расстояния вычисляются матрично через формулу $\|a-b\|^2 = \|a\|^2 + \|b\|^2 - 2a \cdot b$, затем сортировка, выбор k ближайших и голосование через `np.bincount`. Готовые средства классификации не использовались. Построено две модели: со случайным набором признаков (5 из 13) и с фиксированным набором (6 признаков); исследованы $k = 3, 5, 10, 15$ на датасете о вине (178 записей, 3 класса, разделение 80/20). Лучшая точность — 0.9444 (Модель 1 при $k = 3, 5$; Модель 2 при $k = 10, 15$). Основные ошибки — путаница между классами 2 и 3.

3.5 Преимущества

- простота понимания и реализации;
- нет этапа обучения (обучение — просто запоминание данных);
- непараметричность: не предполагает конкретной функциональной формы зависимости;
- естественно работает с любым числом классов.

3.6 Недостатки и ограничения

- предсказание медленное: для каждого объекта нужны расстояния до всех обучающих примеров ($O(N \cdot P)$ на запрос);
- высокая потребность в памяти (хранение всей обучающей выборки);
- “проклятие размерности”: при большом числе признаков расстояния теряют смысл;
- чувствительность к выбору k, метрике расстояния и масштабу признаков;
- плохо работает с категориальными признаками без предварительного кодирования.

3.7 Вопросы защиты с ответами

1. **К какому классу задач относится k-NN?**
   Надзоруемая классификация (и регрессия), опирающаяся на расстояния в пространстве признаков.

2. **Как выбирается параметр k?**
   Экспериментально (кросс-валидация). Малое k — чувствительность к шуму, большое k — размытие границ классов. В работе рассматривались $k = 3, 5, 10, 15$.

3. **Какая метрика расстояния использовалась и почему?**
   Евклидово расстояние — стандарт для k-NN на числовых признаках; адекватно измеряет близость после стандартизации.

4. **Зачем нужна стандартизация признаков перед k-NN?**
   Признаки имеют разные размерности и диапазоны (например, Alcohol ~ 13, Proline ~ 747). Без масштабирования признаки с большими значениями доминируют в расстоянии.

5. **Чем отличаются Модель 1 и Модель 2 в работе?**
   Модель 1 использует случайный набор признаков (5 из 13), Модель 2 — фиксированный набор (6 признаков). Это оценивает влияние состава признаков на качество.

6. **Что показывает матрица ошибок?**
   Распределение предсказаний по истинным и предсказанным классам; диагональ — верные ответы, внедиагональ — ошибки между классами.

7. **Почему ошибки приходятся на классы 2 и 3?**
   Эти классы ближе друг к другу в пространстве признаков, чем класс 1, что затрудняет их раздел k-NN.

4 Деревья решений

4.1 Суть метода

Дерево решений — иерархическая структура правил классификации: каждый внутренний узел содержит проверку по какому-то признаку, ребра соответствуют возможным значениям признака, а листья содержат метки классов. Каждый объект попадает в один лист, давая покрывающий набор конъюнкций. Построение рекурсивно сверху вниз: в узле выбирается признак для разбиения, множество примеров делится на подмножества по значениям признака, для каждого создаётся потомок.

4.2 Критерий разбиения (подход C4.5)

Пусть T — множество примеров. Энтропия:

$$\mathrm{Info}(T) = -\sum_{j=1}^{k} \frac{freq(C_j, T)}{|T|} \log_2 \frac{freq(C_j, T)}{|T|}. \tag{7}$$

После разбиения по признаку X со значениями $A_1, \ldots, A_n$ (подмножества T_i):

$$\mathrm{Info}_X(T) = \sum_{i=1}^{n} \frac{|T_i|}{|T|} \mathrm{Info}(T_i), \qquad \mathrm{splitinfo}(X) = -\sum_{i=1}^{n} \frac{|T_i|}{|T|} \log_2 \frac{|T_i|}{|T|}. \tag{8}$$

Нормированный прирост информации:

$$\mathrm{GainRatio}(X) = \frac{\mathrm{Info}(T) - \mathrm{Info}_X(T)}{\mathrm{splitinfo}(X)}. \tag{9}$$

На каждом шаге выбирается признак с максимальным GainRatio. Множитель splitinfo снижает преимущество признаков с большим числом уникальных значений.

4.3 Особенности небинарного дерева

В отличие от бинарных деревьев (CART), количество потомков узла не ограничено: каждое значение признака порождает отдельного потомка. В работе дерево реализовано через узел со ссылками на потомков (словарь "значение признака → дочерний узел"), а не список-списков. Лист хранит класс большинства и долю объектов положительного класса, которая используется как вероятность предсказания.

4.4 Условия остановки

Рекурсия останавливается, если: все примеры в узле одного класса, достигнут предел максимальной глубины, признаки для разбиения исчерпаны, прирост информации равен нулю или недостаточно примеров.

4.5 Особенности реализации в работе

В лабораторной работе №5 построено небинарное дерево для датасета UCI Mushroom (грибы, съедобный / ядовитый, 22 номинативных признака). Пропуски (в признаке stalk-root) удалены; осталось 5644 записи (3488 съедобных, 2156 ядовитых). Отобрано случайно $\sqrt{22} \approx 4$ признака (зерно 42): cap-shape, cap-surface, gill-color, stalk-color-above-ring. Стратифицирован разделение 70/30 (3951 / 1693). Дерево глубины 4, 85 внутренних узлов, 63 листа. Метрики (положительный класс — ядовитый): Accuracy 0.8547, precision 0.8692, recall 0.7295, AUC-ROC 0.9416, AUC-PR 0.9223. Все метрики и площади под кривыми вычислены собственным кодом (метод трапеций).

4.6 Преимущества

- высокая интерпретируемость: правила легко читаются и объясняются;
- естественно работает с номинативными (категориальными) признаками;
- Capturing нелинейных зависимостей и взаимодействий признаков без явной функциональной формы;
- мало требований к предобработке (не нужно масштабирование).

4.7 Недостатки и ограничения

- склонность к переобучению, особенно на глубоких деревьях (требуется ограничение глубины, обрезка, выбор подмножества признаков);
- нестабильность: небольшие изменения данных могут привести к другому дереву;
- жадный алгоритм выбора признака не гарантирует глобально оптимальное дерево;
- сложно моделировать аддитивные эффекты (например, сумму признаков) без глубоких веток.

4.8 Вопросы защиты с ответами

1. **Что представляет собой дерево решений?**
   Иерархическая структура правил классификации; узлы — проверки признаков, ребра — значения признаков, листья — классы.

2. **Чем алгоритм C4.5 отличается от бинарных деревьев?**
   Количество потомков узла не ограничено, каждое значение признака порождает отдельного потомка.

3. **По какому критерию выбирается признак для разбиения?**
   По максимальному нормированному приросту информации $\mathrm{GainRatio}(X)$.

4. **Как считается энтропия?**
   $\mathrm{Info}(T) = -\sum_j p_j \log_2 p_j$, где p_j — доля примеров класса C_j.

5. **Что делает splitinfo?**
   Корректирует прирост информации, снижая преимущество признаков с большим числом уникальных значений.

6. **Почему удалялись некоторые записи в данных о грибах?**
   В признаке stalk-root встречались пропуски "?", такие объекты исключены перед обучением.

7. **Сколько признаков использовалось и как выбирались?**
   $\sqrt{22} \approx 4$ признака, отобранных случайным образом с фиксированным зерном генератора.

8. **Как вычислялись Accuracy, precision, recall?**
   По формулам из матрицы ошибок, собственным кодом без библиотек.

9. **Что такое AUC-ROC и AUC-PR?**
   Площади под ROC- и PR-кривыми (пары FPR/TPR и Recall/Precision при разных порогах); площадь — методом трапеций, без библиотек.

5 Логистическая регрессия

5.1 Суть метода

Логистическая регрессия — линейная модель для бинарной классификации. Модель оценивает вероятность принадлежности объекта к положительному классу:

$$P(y = 1 \mid x) = \sigma(z), \qquad z = x^\top w, \tag{10}$$

где w — вектор параметров (включая свободный член), x — вектор признаков, $\sigma(\cdot)$ — сигмоидная функция

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \qquad \sigma'(z) = \sigma(z)(1 - \sigma(z)). \tag{11}$$

Сигмоида отображает любое действительное число на отрезок $(0, 1)$, что даёт интерпретацию выхода как вероятности. Порог классификации обычно равен 0.5: объект относится к классу 1, если $p \geq 0.5$.

5.2 Функция потерь и обучение

Используется функция логарифмических потерь (кросс-энтропия, log-loss):

$$L(w) = -\frac{1}{N} \sum_{i=1}^{N} \Big[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \Big], \tag{12}$$

где $p_i = \sigma(x_i^\top w)$. Функция выпукла по w, поэтому градиентные методы сходятся к глобальному минимуму. Градиент:

$$\nabla_w L = \frac{1}{N} X^\top (p - y), \tag{13}$$

обновление весов градиентным спуском:

$$w \leftarrow w - \eta \nabla_w L, \tag{14}$$

где η — скорость обучения. Слишком большое η может привести к дивергенции, слишком маленькое — к медленной сходимости.

5.3 Оптимизация Ньютона

Вместо градиентного спуска используется второй порядок. Гессиан:

$$H = \frac{1}{N} X^\top W X, \qquad W = \operatorname{diag}(p_i(1 - p_i)), \tag{15}$$

обновление:

$$w \leftarrow w - H^{-1} \nabla_w L. \tag{16}$$

Метод Ньютона обычно сходится за меньшее число итераций, но требует обращения матрицы гессиана размера $(d + 1) \times (d + 1)$ на каждой итерации, что дороже при большом числе признаков.

5.4 Метрики классификации

По матрице ошибок (TP, TN, FP, FN):

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad \text{F1} = \frac{2 \cdot \text{Precision}}{\text{Precision} + } \tag{17}$$

F1-Score — гармоническое среднее precision и recall, устойчивое к дисбалансу классов.

5.5 Особенности реализации в работе

В лабораторной работе №6 реализована логистическая регрессия “с нуля” на NumPy/Pandas для датасета Титаника (891 запись, цель Survived, доля выживших 38,4%). Предобработка без утечки данных: разделение 80/20 (712/179) до заполнения пропусков и стандартизации, статистики только из обучения, one-hot кодирование порта посадки, 9 признаков в модели. Исследованы гиперпараметры: learning rate $\{0.01, 0.1, 0.5\}$, итерации $\{100, 500, 1000\}$, методы градиентного спуска и Ньютона. Наилучший результат — градиентный спуск, lr = 0.1, 500 итераций: accuracy 0.7765, precision 0.6866, recall 0.7077, F1 0.6970 (TP = 46, TN = 93, FP = 21, FN = 19). Ньютон сходится быстро, но не даёт преимущества в точности на тесте.

5.6 Преимущества

- вероятностный вывод (выдаёт оценку вероятности класса, а не только метку);
- быстрая сходимость, простая реализация;
- хорошая интерпретируемости: знаки и величины весов показывают влияние признаков;
- хорошая базовая модель для бинарной классификации.

5.7 Недостатки и ограничения

- линейная граница разделения классов: $p \geq 0.5$ эквивалентно $x^\top w \geq 0$;
- плохо справляется со сложными нелинейными зависимостями и взаимодействиями признаков без инженерии признаков;
- чувствительна к дисбалансу классов (точность по меньшему классу может быть низкой при высоком общем accuracy);
- требует масштабирования признаков для устойчивой сходимости градиентного спуска.

5.8 Вопросы защиты с ответами

1. **В чём отличие логистической регрессии от линейной?**
   Линейная регрессия предсказывает непрерывное значение и минимизирует среднеквадратичную ошибку. Логистическая регрессия для классификации: через сигмоиду выдаёт вероятность в $(0, 1)$, функцией потерь служит кросс-энтропия (log-loss), порог 0.5 превращает вероятность в класс 0 или 1.

2. **Зачем нужна сигмоида и какова её производная?**
   Отображает любое z на $(0, 1)$, давая интерпретацию как вероятности. Производная $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ используется в градиенте и гессиане.

3. **Как выбирается порог классификации, и что изменится при его сдвиге?**
   Стандартный порог — 0.5. Повышение порога снижает число ложноположительных ответов (растёт precision) и увеличивает ложноотрицательные (падает recall). Понижение — наоборот.

4. **Зачем нужна стандартизация признаков?**
   Признаки имеют разные диапазоны (возраст до 80, стоимость билета до 512). Стандартизация приводит их к сравнимому масштабу, ускоряет и стабилизирует сходимость градиентного спуска.

5. **В чём преимущество и недостаток метода Ньютона?**
   Преимущество — обычно меньше итераций до сходимости благодаря второй производной. Недостаток — необходимость обращать матрицу гессиана размера $(d + 1) \times (d + 1)$ на каждой итерации, что дороже при большом числе признаков.

6. **Можно ли сказать, что логистическая регрессия — линейная модель?**
   Да: решение принимается по линейной комбинации признаков $z = x^\top w$; поскольку сигмоида монотонна, $p \geq 0.5 \iff x^\top w \geq 0$ — линейная граница в пространстве признаков.

6 Сравнительный обзор методов

6.1 Таблица сравнения

Таблица 1: Сравнительные характеристики четырёх методов модуля 2.

Метод	Тип задачи	Качество на тесте (это работа)	Преимущества	Ограничения
Линейная регрессия (МНК)	Регрессия	Жильё Калифорнии, R^2 до 0.54	Простота, интерпретируемость, аналитическое решение	Линейная зависимость, чувствительность к мультиколлинеарности и выбросам
k-NN	Классификация/регрессия	Вино, accuracy до 0.9444	Нет обучения, непараметричность, любое число классов	Медленное предсказание, чувствительность к k, масштабу и размерности
Дерево решений	Классификация	Грибы, accuracy 0.8547, AUC-ROC 0.9416	Интерпретируемость, номинативные признаки, нелинейность	Риск переобучения, нестабильность, жадность алгоритма
Логистическая регрессия	Бинарная классификация	Титаник, accuracy 0.7765, F1 0.6970	Вероятности, быстрая сходимость, хорошая база	Линейная граница, сложности с нелинейными зависимостями

6.2 Когда какой метод наиболее эффективен

- **Линейная регрессия** — когда цель непрерывная и связь с признаками приближённо линейна (прогноз цен, спроса), нужна интерпретируемость эффектов факторов.
- **k-NN** — на маленьких/средних выборках, когда расстояние между объектами осмысленно, нет явной функциональной зависимости (рекомендательные системы, распознавание образов в низкоразмерном пространстве).
- **Дерево решений** — при смешанных числовых и категориальных признаках, когда важна понятная логика принятия решения (кредитный скоринг, медицинская диагностика).
- **Логистическая регрессия** — для бинарной классификации с вероятностным выводом (отток, скоринг рисков, выживание), особенно как базовая, легко обучаемая модель.

7 Общие вопросы защиты по модулю

1. **В чём разница между регрессией и классификацией?**
   Регрессия предсказывает непрерывное числовое значение, классификация — дискретный метку класса.

2. **Зачем нужны обучающая и тестовая выборки?**
   Для оценки обобщающей способности модели на данных, не использовавшихся при обучении, и выявления переобучения.

3. **Что такое переобучение и как с ним бороться?**
   Модель слишком точно подстраивается под обучающие данные (включая шум) и плохо обобщается. Борьба: ограничение сложности модели, кросс-валидация, выбор подмножества признаков, регуляризация.

4. **Почему важна стандартизация признаков?**
   Методы на основе расстояний (k-NN) и градиентного спуска (логистическая регрессия) чувствительны к масштабу признаков; стандартизация приводит их к сравнимым диапазонам.

5. **Почему все методы в работе реализованы без sklearn?**
   Для понимания внутреннего устройства алгоритмов: формул, оптимизации, расчёта метрик от первого лица.

6. **Как выбиралась "главная" метрика в каждой работе?**
   Для регрессии — R^2; для классификации — accuracy, precision, recall, F1 (для несбалансированны
   классов F1 более информативна, чем accuracy); для деревьев — дополнительно AUC-ROC и AUC-PR.