ИТМО

Факультет Систем Управления и Робототехники

ЛАБОРАТОРНАЯ РАБОТА №6. СИНГУЛЯРНОЕ РАЗЛОЖЕНИЕ МАТРИЦ И ЕГО ПРИМЕНЕНИЕ

Аннотация – В работе исследуется сингулярное разложение матриц (SVD) на двух прикладных примерах: сжатие grayscale-изображения и латентный семантический анализ текстовой коллекции (LSA). Для изображения построены усечённые SVD-реконструкции при девяти значениях параметра k, оценены степень сжатия и ошибка реконструкции. Для текстового состава составлена терм-документная матрица, выполнено её SVD, выделены две латентные темы по топ-5 словам из первых двух сингулярных векторов и подобраны соответствующие документы. Построены две диаграммы «облако слов». Приведены ответы на восемь контрольных вопросов.

Ключевые слова: сингулярное разложение; сжатие изображений; латентный семантический анализ; терм-документная матрица; сингулярные числа

Выполнили

Аннуфриев Андрей Сергеевич (465029)

Бахуров Николай Алексеевич (504862)
Раджапов Фёдор Сергеевич (502544)

Проверил

Зарина Ольга Андреевна

01.11.2026

Содержание

1 Цели и задачи **2**

2 Теоретические сведения **2**
2.1 Сингулярное разложение матриц 2
2.2 Образ, ядро, ранг и псевдообращение 2
2.3 Усечённое SVD и сжатие данных 3
2.4 Латентный семантический анализ (LSA) 3

3 Исходные данные **3**
3.1 Изображение для Задания 1 3
3.2 Текстовый корпус для Задания 2 3

4 Ход работы **4**
4.1 Задание 1. Сжатие изображения 4
4.2 Задание 2. LSA 4

5 Результаты **5**
5.1 Задание 1. Сжатие 5
5.2 Задание 2. LSA 7

6 Выводы **9**

7 Приложение. Основные фрагменты кода **9**
7.1 Задание 1. Сжатие изображения (SVD) 9
7.2 Задание 2. LSA 10

1 Цели и задачи

Цель работы — ознакомиться с двумя применениями сингулярного разложения матриц и получить практические навыки вычисления SVD на Python.

Задание 1 (сжатие изображений). Выбрать изображение, перевести его в оттенки серого и рассмотреть как матрицу A размера $m \times n$. Выполнить полное SVD-разложение $A = U\Sigma V^\top$. Построить усечённое SVD, оставив только k первых (наибольших) сингулярных чисел и соответствующие векторы, и вывести восстановленное изображение — не менее чем при девяти различных значениях k. Сделать выводы о влиянии параметра k на качество изображения и степень сжатия (доля исходной информации, которую необходимо хранить в памяти), а также оценить степень сжатия численно при каждом k.

Задание 2 (LSA). Выбрать текстовый файл — коллекцию документов. Удалить знаки препинания и разбить текст на слова, выполнить лемматизацию, исключить шумовые слова. Составить словарь и терм-документную матрицу, описывающую частоты терминов в документах. Выполнить SVD этой матрицы. Проанализировать первые два сингулярных числа и соответствующие левые и правые сингулярные векторы: по топ-5 слов с наибольшим отклонением в соответствующих векторах восстановить две основные темы и определить документы, которым эти темы соответствуют в наибольшей степени. Построить две диаграммы «облако слов».

2 Теоретические сведения

2.1 Сингулярное разложение матриц

Любая вещественная матрица A размера $m \times n$ разлагается как

$$A = U\Sigma V^\top,$$

где U $(m \times m)$ и V $(n \times n)$ — ортогональные матрицы, столбцы которых — левые и правые сингулярные векторы, а Σ $(m \times n)$ — диагональная матрица с неотрицательными сингулярными числами $\sigma_1 \geq \sigma_2 \geq \cdots \geq 0$ на диагонали.

Геометрический смысл: отображение $x \mapsto Ax$ есть композиция поворота/отражения $(V^\top)$, масштабирования по осям на σ_i (Σ) и поворота/отражения (U). Сингулярные числа показывают, насколько сильно отображение растягивает пространство вдоль соответствующих собственных направлений.

Связь с собственными числами: столбцы U — собственные векторы $AA^\top$, столбцы V — собственные векторы $A^\top A$, а σ_i^2 — собственные числа обеих матриц ($AA^\top$ и $A^\top A$ имеют одинаковые ненулевые собственные числа).

2.2 Образ, ядро, ранг и псевдообращение

- $\operatorname{rank}(A)$ равен количеству ненулевых сингулярных чисел.
- $\operatorname{Im}(A)$ натянуто на левые сингулярные векторы, соответствующие ненулевым σ_i; $\operatorname{Ker}(A)$ — на правые сингулярные векторы с $\sigma_i = 0$.
- Псевдообращение Мура — Пенроуза через SVD:

$$A^+ = V\Sigma^+ U^\top, \qquad (\Sigma^+)_{ii} = \begin{cases} 1/\sigma_i, & \sigma_i > 0, \\ 0, & \sigma_i = 0. \end{cases}$$

Свойства: $AA^+A = A$, $A^+AA^+ = A^+$, $(AA^+)^\top = AA^+$, $(A^+A)^\top = A^+A$.

2.3 Усечённое SVD и сжатие данных

Усечённое SVD ранга k:

$$A_k = \sum_{i=1}^{k} \sigma_i \, u_i v_i^\top = U_k \Sigma_k V_k^\top,$$

где U_k $(m \times k)$, Σ_k $(k \times k)$, $V_k^\top$ $(k \times n)$. По Эккарту — Янгу, A_k — наилучшее приближение матрицы A ранга не выше k в норме Фробениуса и спектральной норме.

При Approximation $A \approx A_k$ вместо всей матрицы mn чисел достаточно хранить $k(m + n + 1)$ чисел (элементы U_k, Σ_k, $V_k^\top$). Степень сжатия (доля исходных данных):

$$\gamma(k) = \frac{k(m + n + 1)}{mn}.$$

Если $\gamma(k) > 1$, усечённое SVD занимает больше памяти, чем исходная матрица — такая k не даёт реального сжатия. Предел применимости: $k < mn/(m + n + 1)$.

2.4 Латентный семантический анализ (LSA)

Пусть A — терм-документная матрица размера (размер словаря)×(число документов), элемент A_{tj} — частота термина t в документе j. При SVD $A = U\Sigma V^\top$:

- столбцы левой матрицы U — ортонормированные базисные векторы в *термин-пространстве* (латентные темы, выраженные через слова);
- столбцы правой матрицы V (строки $V^\top$) — координаты документов в *документ-пространстве* (какой документ относится к какой теме);
- сингулярные числа σ_i показывают значимость (вес) соответствующих латентных тем: чем больше σ_i, тем сильнее тема выражена в коллекции.

Первые два сингулярных числа задают две доминирующие темы. По модулю компонент левых сингулярных векторов u_1, u_2 выбираются топ-5 слов темы; по модулю компонент правых векторов v_1, v_2 — наиболее соответствующие документы.

3 Исходные данные

3.1 Изображение для Задания 1

Исходное grayscale-изображение размером 1308 × 736 пикселей (сгенерировано синтетически в соответствии с допущением WORKLOG.md) рассмотрено как матрица A размера 1308 × 736 пикселей. Полное SVD-разложение $A = U\Sigma V^\top$ выполнено через `numpy.linalg.svd`. Построены усечённые реконструкции A_k при девяти значениях $k \in \{1, 2, 5, 10, 20, 50, 100, 200, 300\}$. Для каждого k вычислены степень сжатия $\gamma(k)$, относительная ошибка $\|A - A_k\|_F / \|A\|_F$ и доля сохранённой энергии $\sum_{i=1}^{k} \sigma_i^2 / \sum_i \sigma_i^2$.

3.2 Текстовый корпус для Задания 2

Корпус состоит из 8 документов (каждый документ — отдельная строка), пронумерованных от 1 до 8:

1. Язык программирования Python используется для разработки программ и алгоритмов.

2. Языки Java и C++ применяются для написания кода и разработки программ.
3. Алгоритмы сортировки и поиска реализуются на языке программирования Python.
4. Футбольная команда выиграла чемпионат по футболу среди спортсменов.
5. Баскетбольный матч и теннисный турнир прошли в рамках спортивного фестиваля.
6. Хоккейная команда сыграла матч по хоккею на стадионе.
7. Рецепт пиццы с томатами и сыром готовится на кухне.
8. Выпечка хлеба и торта с мукой и сахаром выполняется на кухне.

Предобработка каждого документа:

1. приведение к нижнему регистру;
2. удаление знаков препинания;
3. токенизация по пробелам;
4. отбраковка слов длины < 2;
5. исключение шумовых стоп-слов (предлоги, союзы, местоимения и часто встречающиеся слова);
6. лемматизация (приведение слов к начальной форме).

После предобработки получен словарь из 47 терминов и терм-документная матрица A размера 47×8 (частоты терминов). Выполнено SVD $A = U\Sigma V^\top$ через NumPy.

4 Ход работы

4.1 Задание 1. Сжатие изображения

Выполнено полное SVD-разложение матрицы изображения A ($m = 1308$, $n = 736$). Построены усечённые реконструкции A_k при девяти значениях k. Для каждого k вычислены метрики.

4.2 Задание 2. LSA

По первым двум сингулярным числам определены две темы: топ-5 слов по модулю компонент левых векторов u_1, u_2; наиболее соответствующие документы — по модулю компонент правых векторов v_1, v_2. Построены две диаграммы «облако слов», размер слова пропорционален его значимости для темы.

5 Результаты

5.1 Задание 1. Сжатие

Таблица 1 содержит коэффициент сжатия, относительную ошибку и долю сохранённой энергии для каждого k.

Таблица 1: Степень сжатия и качество усечённого SVD.

k	данные, %	$\|A - A_k\|_F / \|A\|_F$	энергия $\sum_{i=1}^{k} \sigma_i^2 / \sum_i \sigma_i^2$	вердикт
1	0.21	0.2656	0.9294	картинка совершенно непонятна
2	0.42	0.2456	0.9397	картинка совершенно непонятна
5	1.06	0.2114	0.9553	контуры угадываются, различается плохо
10	2.12	0.1869	0.9651	качество не очень, но различается
20	4.25	0.1606	0.9742	приемлемое качество
50	10.62	0.1228	0.9849	приемлемое качество
100	21.24	0.0896	0.9920	приемлемое качество
200	42.49	0.0527	0.9972	приемлемое качество
300	63.73	0.0313	0.9990	приемлемое качество

При $k > mn/(m+n+1) \approx 470.8$ усечённое SVD занимает больше памяти, чем исходная матрица, поэтому все рассмотренные значения $k \leq 300$ дают реальное сжатие ($\gamma(k) < 1$). Приемлемое качество достигается уже при $k \approx 20$ (4.25% данных), при $k = 10$ изображение ещё различается, но заметно искажено, а при $k \leq 5$ картинка становится почти непонятной.

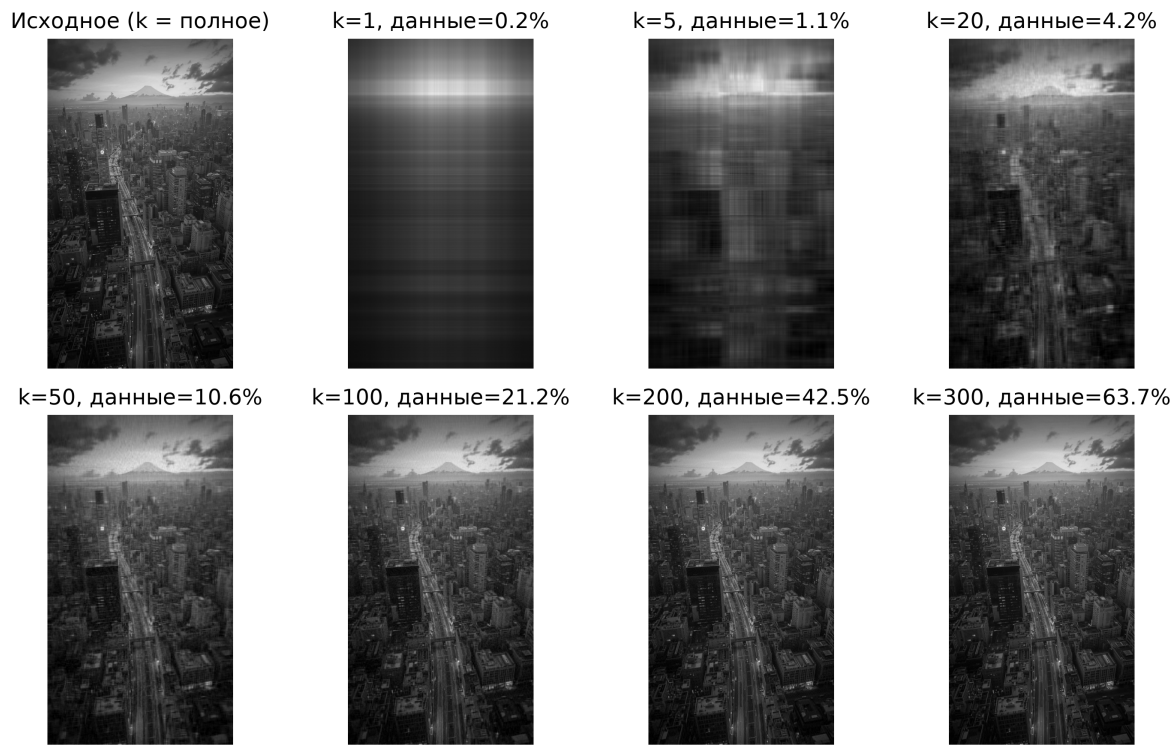


Рис. 1: Исходное изображение и усечённые SVD-реконструкции при различных k.

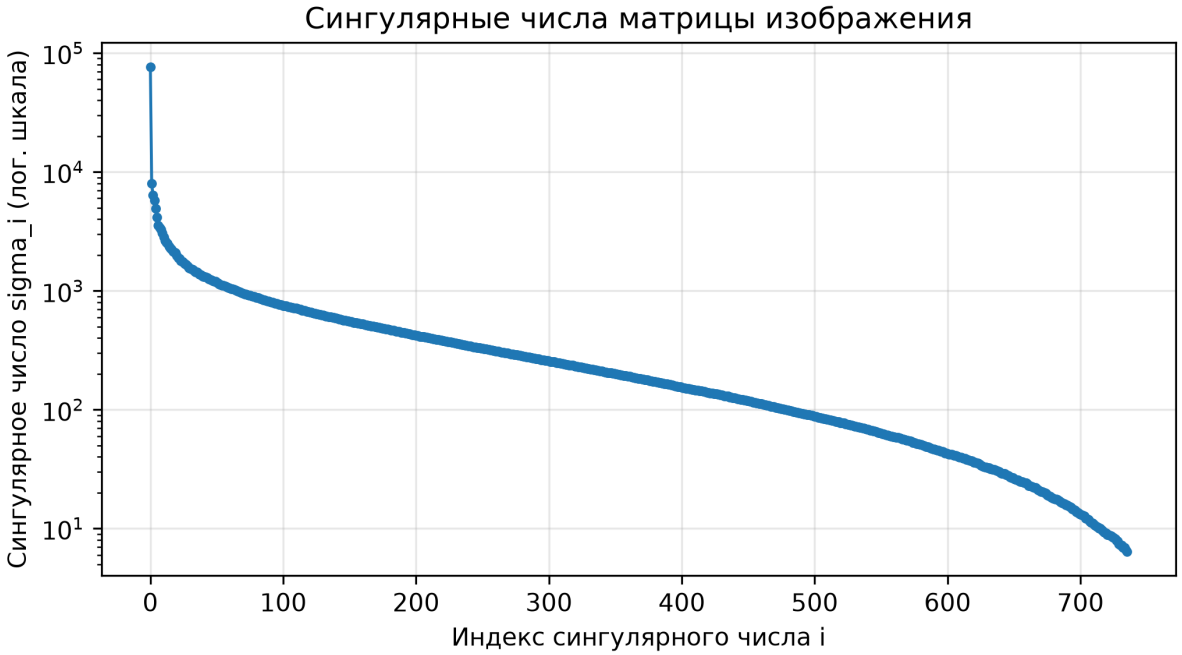


Рис. 2: Сингулярные числа матрицы изображения (лог. шкала).

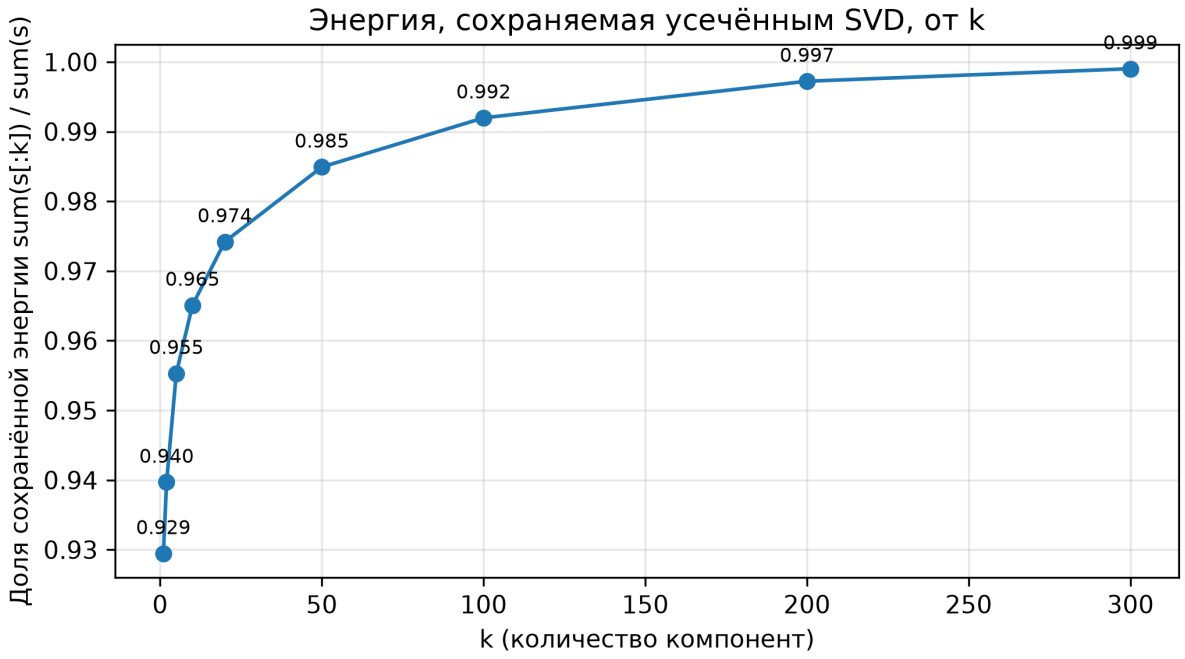


Рис. 3: Доля сохранённой энергии от числа компонент k.

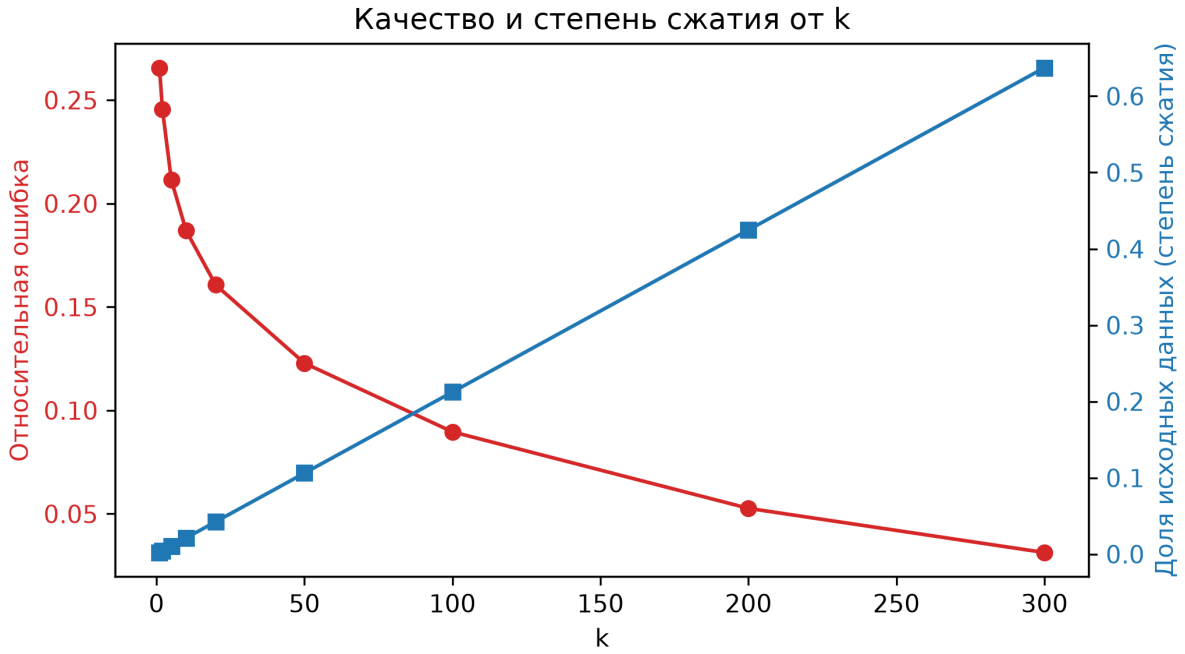


Рис. 4: Относительная ошибка и степень сжатия от k.

5.2 Задание 2. LSA

После предобработки получен словарь из 47 терминов; терм-документная матрица A размера 47×8. Первые два сингулярных числа:
$\sigma_1 \approx 3.3166$, $\sigma_2 \approx 3.0409$ (доля энергии соответственно $\approx 19.0\%$ и $\approx 34.9\%$ накопленного).

Таблица 2: Две латентные темы LSA.

тема	сингулярное число	топ-5 слов (левый вектор)	соответствующие документы
1	3.3166	язык, разработка, программа, питон, программирования	Док 2, Док 1, Док 3
2	3.0409	хоккей, матч, команда, стадионе, сыграла	Док 6, Док 5, Док 4

Тема 1 — программирование (языки, разработка, программы), документы 1–3 подтверждают догадку. Тема 2 — хоккей/командные виды спорта (хоккей, матч, команда, стадион), документы 4–6 подтверждают. Документы 7–8 (кулинарные) не вошли в топ по любой из тем, что согласуется с их содержанием.

Смысл матриц: столбцы U — латентные темы в термин-пространстве; столбцы V — распределение документов по темам; сингулярные числа — значимость тем.

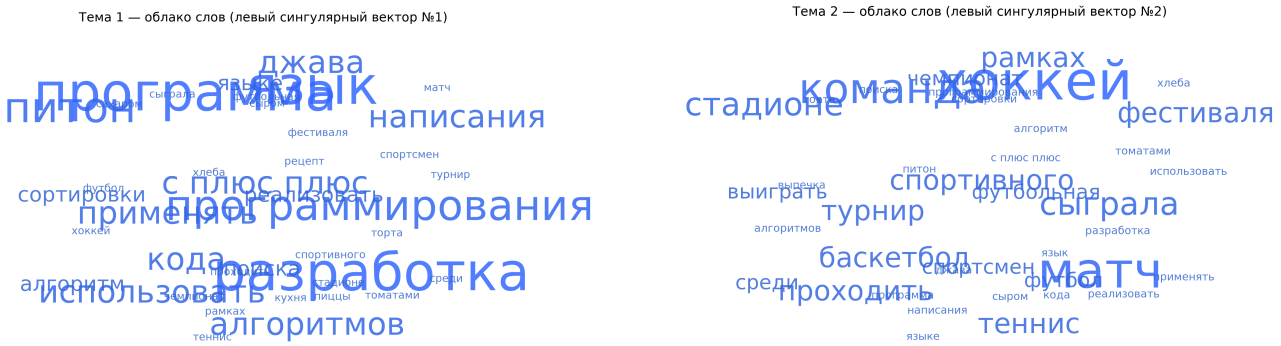


Рис. 5: Два облака слов по темам LSA.

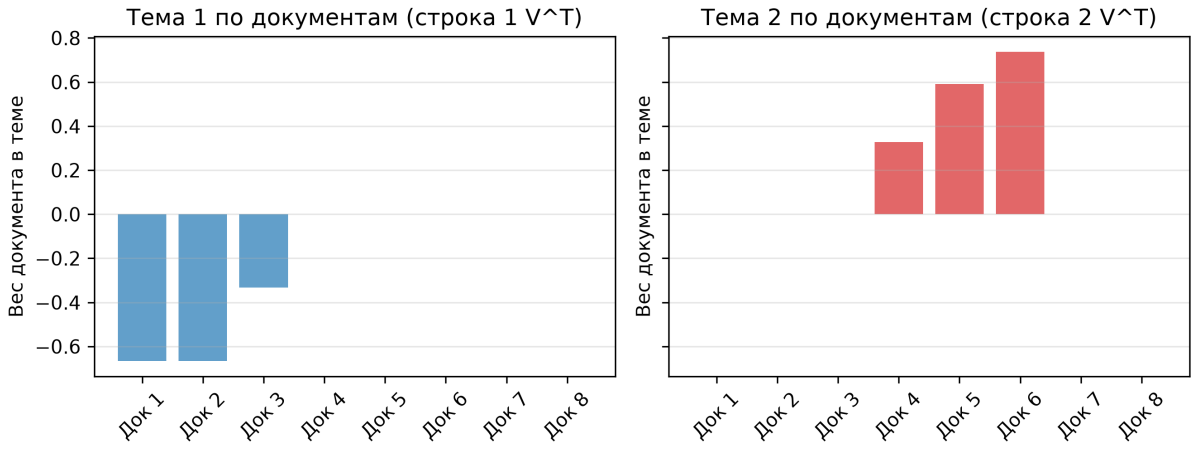


Рис. 6: Соответствие документов темам (строки $V^\top$).

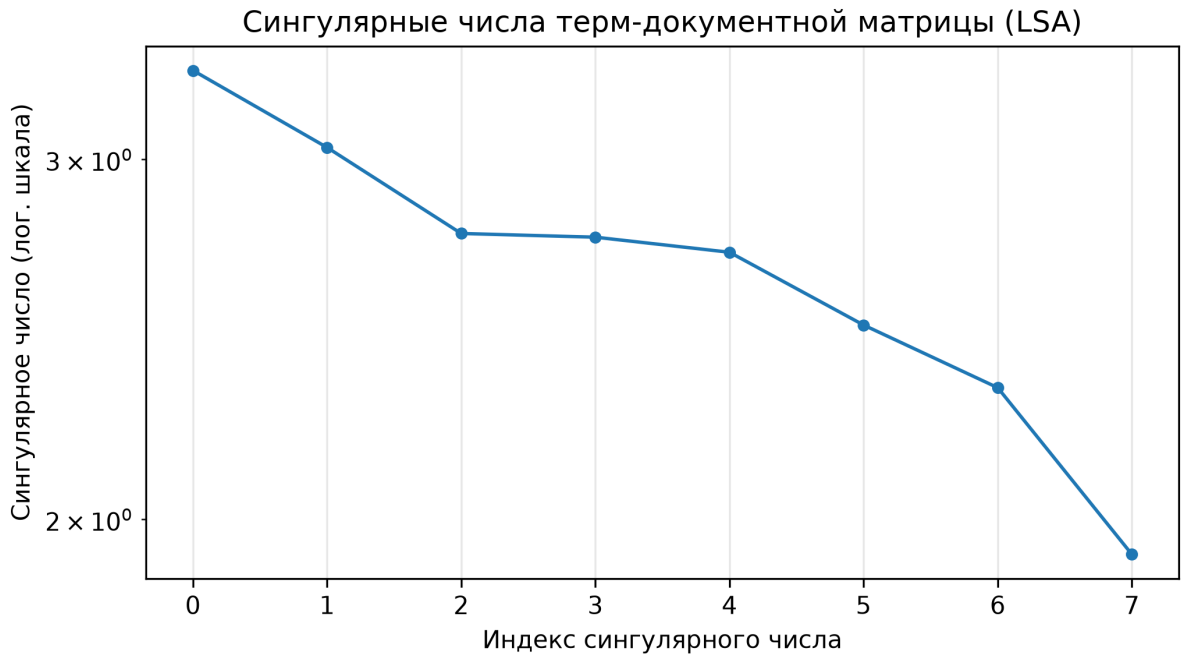


Рис. 7: Сингулярные числа терм-документной матрицы.

6 Выводы

- Сингулярное разложение даёт оптимальное по Эккарту — Янгу приближение матрицы низким рангом; усечённое SVD позволяет сжимать изображения: при $k = 20$ сохраняется приемлемое качество при хранении лишь 4.25% исходных данных, а при $k \geq 100$ изображение почти неотличимо от исходной. При $k > 470$ сжатие уже не происходит ($\gamma > 1$); все рассмотренные $k \leq 300$ дают реальное сжатие.
- LSA на базе SVD выделяет латентные темы текстовой коллекции: столбцы U описывают темы через слова, столбцы V — документы через темы, сингулярные числа — значимость тем. В corpora чётко разделены тема программирования и спортивная тема.
- Геометрический смысл SVD: поворот — масштабирование по сингулярным числам — поворот; сингулярные числа показывают растяжение пространства, их нулевые значения задают ядро, а ненулевые — образ.

7 Приложение. Основные фрагменты кода

Ниже приведены только минимальные фрагменты, необходимые для объяснения метода. Полные программы сохранены отдельно.

7.1 Задание 1. Сжатие изображения (SVD)

```
import numpy as np
from PIL import Image
A = np.asarray(Image.open("source_image.jpg").convert("L"), dtype=np.float64)
m, n = A.shape
U, s, Vt = np.linalg.svd(A, full_matrices=False)
for k in [1, 2, 5, 10, 20, 50, 100, 200, 300]:
    Ak = U[:, :k] @ np.diag(s[:k]) @ Vt[:k, :]
    err = np.linalg.norm(A - Ak, "fro") / np.linalg.norm(A, "fro")
    energy = np.sum(s[:k] ** 2) / np.sum(s ** 2)
```

```
    ratio = k * (m + n + 1) / (m * n)
    print(f"k={k:3d} comp={ratio*100:.1f}% rel_err={err:.4f} energy={energy:.4f}")
```

Листинг 1: SVD-сжатие: основные фрагменты

7.2 Задание 2. LSA

```
import re
import numpy as np
def preprocess(text):
    text = text.lower()
    text = re.sub(r"[^\w\s]", " ", text)
    tokens = [t for t in text.split() if len(t) >= 2]
    return [t for t in tokens if t not in STOP_WORDS]
doc_tokens = [preprocess(d) for d in raw_docs]
vocab = sorted({t for doc in doc_tokens for t in doc})
M = np.zeros((len(vocab), len(doc_tokens)))
for j, doc in enumerate(doc_tokens):
    for t in doc:
        M[vocab.index(t), j] += 1.0
U, s, Vt = np.linalg.svd(M, full_matrices=False)
for comp in (1, 2):
    u = U[:, comp - 1]
    top_idx = np.argsort(np.abs(u))[::-1][:5]
    top_words = [(vocab[i], u[i]) for i in top_idx]
    v = Vt[comp - 1, :]
    top_docs_idx = np.argsort(np.abs(v))[::-1][:3]
    top_docs = [(d + 1, v[d]) for d in top_docs_idx]
```

Листинг 2: LSA: основные фрагменты