В этой лабораторной вы познакомитесь с двумя замечательными применениями сингулярного разложения матриц.

Задание 1. Сжатие изображений. Одно из самых наглядных применений сингулярного разложения.

- Выберите какое-нибудь изображение, преобразуйте его к оттенкам серого и работайте с ним как с матрицей.
- Выполните SVD-разложение получившейся матрицы.
- Найдите «укороченное» SVD-разложение этой матрицы, оставив только k первых (наибольших) сингулярных чисел и соответствующих им векторов. Выведите полученное изображение. Сделайте это для не менее 9 различных значений k.
- Сделайте выводы о влиянии параметра k на качество вашего изображения и степень сжатия (какую долю от исходной информации необходимо хранить в памяти). При каких значениях k картинка имеет приемлемое качество? При каких значениях качество уже не очень, но картинка всё ещё различима? Для каких k картинка становится совершенно непонятной? Оцените численно степень сжатия изображения при каждом из рассмотренных вами значений параметра k.

Ожидаемые результаты:

- Приведено выбранное изображение в оттенках серого.
- Приведены 9 различных значений k и полученные для них изображения. Для каждого случая приведена степень сжатия.
- Написаны выводы по проделанной работе.

Задание 2. Latent Semantic Analysis. Перед выполнением задания самостоятельно ознакомьтесь с материалом по теме LSA.

- Выберите один из текстовых файлов, доступных по ссылке. Каждый файл представляет собой массив строк (документов), с которыми вам предстоит работать. Прочитайте несколько предложений и подумайте, какие темы можно встретить среди документов?
- Удалите знаки препинания и разделите текст на отдельные слова.
- Сделайте лемматизацию текста, приведя все слова к их начальной форме. Для этого можно использовать библиотеку `pymorphy2` языка Python.
- Исключите из текста «шумовые» слова, не несущие значительной смысловой нагрузки. Такими являются *предлоги*, *союзы*, *местоимения*, а также часто встречающиеся слова. Для этого предлагается использовать библиотеку `nltk`.

- Составьте словарь из оставшихся слов и создайте терм-документную матрицу, описывающую частоту употребления терминов в коллекции документов.
- Выполните SVD-разложение получившейся матрицы.
- Постарайтесь ответить на вопросы: Какой смысл имеют столбцы и строки матриц U и V? Какой смысл имеют сингулярные числа матрицы Σ?
- Проанализируйте первые два сингулярных числа и соответствующие им правые и левые сингулярные векторы. Используя топ-5 слов с наибольшим отклонением в соответствующих векторах, восстановите основные две темы в тексте и проверьте вашу догадку.
- Определите документы, для которых найденные темы соответствуют в наибольшей степени, основываясь на сингулярном разложении.
- Создайте две диаграммы «облако слов» с каждым словом из словаря, где размер будет отражать значимость этого слова для темы.
- Сделайте выводы по проделанной работе.

Ожидаемые результаты:

- Приведены все документы из выбранного файла и его номер.
- Приведен результат полученный после удаления знаков препинания и шумовых слов, а также леммизации текста.
- Приведены 5 наиболее важных слов для каждого из двух наибольших сингулярных чисел и по ним определены две наиболее значимые темы.
- Приведены номера документов, которым в наибольшей степени соответствуют найденным темам.
- Приведены две диаграммы облаков со всеми словами, где размер слов указывает принадлежность их к соответствующей теме.
- Написаны выводы по проделанной работе.

Контрольные вопросы по проделанной работе:

1. Какие свойства ортогональных матриц вам известны?
2. Какие свойства симметричных матриц вам известны? Как связаны собственные числа матриц $AA^\top$ и $A^\top A$?
3. Какой геометрический смысл неквадратных матриц? Как rank произведения матриц связан с рангами каждой?
4. Что такое сингулярное разложение матриц? Какой геометрический смысл сингулярного разложения? Что обозначает величина сингулярных чисел?
5. Как сингулярное разложение связано с Im (Range) и Ker (Nullspace) матриц?
6. Как задается «укороченное» SVD разложение? В каком случае результат произведения «укороченных» матриц совпадет с исходной матрицей? Как метод укорочения применяется на практике?
7. Что такое псевдообращение матрицы, как его найти с помощью сингулярного разложения? Какие свойства псевдообратных матриц?
8. Какой смысл имеют левые и правые сингулярные векторы в алгоритме LSA? Что показывают сингулярные числа?